

基于 EEG 的运动想象状态分类

陈博

指导老师：伍冬睿教授

摘要

本研究针对跨被试的运动想象脑电信号分类问题，比较了深度学习与传统机器学习两类方法的性能。在只有 200 次 trial、每位被试数据量有限的条件下，我们首先采用轻量化的 EEGNet 模型，结合 Euclidean-space Data Alignment (EA)、Adam 优化与早停策略进行四折 LOSO 验证。随后，我们基于 Common Spatial Pattern (CSP) 和线性支持向量机 (SVM) 的传统 pipeline，依次引入欧式对齐 (EA)、8–16 Hz 带通滤波 (BP) 及视觉提示后 0–1.5 s 数据裁剪 (CR)，四折平均准确率从最初的 0.53 提升至 0.69。由于深度学习方法过拟合问题严重，输出模型不稳定，最终选择机器学习方法进行测试集预测。

关键词：运动想象；EEGNet；欧式对齐；共空间模式；支持向量机

1 介绍

本次任务是基于 EEG 的运动想象数据 (MI) 的二分类问题。训练集四个被试，测试集四个被试，每个被试 200 个 trial。

最初，我们尝试使用深度学习模型 EEGNet 进行跨被试分类，并设计了四折 LOSO 验证（每折用三位被试数据训练，一位被试数据验证）。实验结果表明，虽然加入 EA 后模型性能有所提升，但在部分折次出现过拟合和损失震荡，且总体准确率未能稳定，因此深度方法在本数据量受限的场景下并非最优选择。

随后，我们转向传统机器学习方案，并在原始 CSP + 线性 SVM 基线上逐步添加预处理操作：首先加入公共平均参考 (EA)，再加入 8–16 Hz 带通滤波 (BP)；最后裁剪视觉提示后 0–1.5 s 信号 (Cropping, CR)。最终的最佳流程为

$$\text{BP} + \text{CR} + \text{EA} + \text{CSP} + \text{SVM}.$$

为增强稳健性，还采用了 Bagging 思想，将 4 折 LOSO 模

型与一个全量训练模型集成，共 5 个基模型进行多数表决。

本文其余结构安排如下：第 2 节介绍相关方法，包括 EA、CSP、SVM 以及 EEGNet；第 3 节详细描述实验设计与结果，分为深度学习部分与传统机器学习部分；第 4 节总结研究结论并讨论未来改进方向。

2 方法

2.1 传统机器学习方法

2.1.1 带通滤波

在运动想象任务中，人脑对应的脑电频率主要集中在 α 波 (8–12 Hz) 和 β 波 (13–30 Hz) 区间。为了增强任务相关信号，本文对原始 EEG 进行 8–16 Hz 带通滤波：

$$X_{\text{filt}}(t) = \text{BP}(X(t); 8, 16),$$

其中 $\text{BP}(\cdot)$ 表示带通滤波操作，可去除低频漂移和高频噪声，提高信噪比。

2.1.2 采样点选择

原始试验数据截取自 0.5–3.5 s，采样率为 250 Hz，共 750 个采样点。我认为被试执行两类运动想象任务的时间可能根本用不了 3s，后面的数据反而会引入噪声，所以应该切割数据，只保留较为前面的一部分数据。最后根据实验，本文选择使用运动想象任务视觉提示出现后 1.5s 内的数据，即：

$$X_{\text{crop}} = X_{\text{filt}}[0.0\text{s} : 1.5\text{s}].$$

2.1.3 欧式对齐 (EA)

为减小不同通道之间的基线漂移和公共噪声，采用 Euclidean-space Data Alignment 方法进行公共平均参考 [2]。设对齐前的第 n 次 trial 数据为 \tilde{X}_n ，其协方差矩阵为

$\tilde{X}_n \tilde{X}_n^T$ ，则公共平均协方差矩阵

$$\bar{R} = \frac{1}{N} \sum_{n=1}^N \tilde{X}_n \tilde{X}_n^T.$$

使用 $\bar{R}^{-\frac{1}{2}}$ 对每个 trial 进行对齐后，新的 trial 数据记为

$$X_n = \bar{R}^{-\frac{1}{2}} \tilde{X}_n.$$

此时，所有对齐后 trial 的平均协方差矩阵为：

$$\begin{aligned} \frac{1}{N} \sum_{n=1}^N X_n X_n^T &= \frac{1}{N} \sum_{n=1}^N \bar{R}^{-\frac{1}{2}} \tilde{X}_n \tilde{X}_n^T \bar{R}^{-\frac{1}{2}} \\ &= \bar{R}^{-\frac{1}{2}} \left(\frac{1}{N} \sum_{n=1}^N \tilde{X}_n \tilde{X}_n^T \right) \bar{R}^{-\frac{1}{2}} \\ &= \bar{R}^{-\frac{1}{2}} \bar{R} \bar{R}^{-\frac{1}{2}} = I. \end{aligned} \quad (1)$$

也就是说，EA 操作后，所有 trial 的平均协方差都被标准化为单位阵，从而保证不同试验间的协方差结构一致。

2.1.4 共空间模式 (CSP)

共空间模式 (Common Spatial Pattern, CSP) 是一种有监督的空间滤波技术，常用于二分类的运动想象 EEG 信号特征提取 [3]。其基本思路是设计一组空间滤波器，使得滤波后不同类别信号的方差（即功率）之比最大化，从而增强两类信号之间的可区分性。

具体地，设第 i 次试验属于第 c 类的数据为矩阵 $X_i^c \in \mathbb{R}^{N \times T}$ ，其中 N 是通道数， T 是时间采样点数。首先对每个 trial 做中心化和归一化预处理，然后计算两类数据的平均协方差矩阵：

$$R_c = \frac{1}{K_c} \sum_{i=1}^{K_c} X_i^c (X_i^c)^T, \quad c = 1, 2, \quad (2)$$

其中 K_c 是第 c 类 trial 的数量。

CSP 的目标是找到一个投影矩阵 $W \in \mathbb{R}^{N \times M}$ ($M \leq N$)，将原始信号映射到低维空间：

$$x_{\text{CSP}}(t) = W^T x(t),$$

使得类别 1 在滤波后投影信号的方差最大，而类别 2 的方差最小。等价地， W 的列向量应满足广义特征值分解：

$$W^T R_1 W = \Lambda_1, \quad (3)$$

$$W^T R_2 W = \Lambda_2, \quad (4)$$

其中 $\Lambda_1 + \Lambda_2 = I$ ， Λ_1, Λ_2 为对角矩阵。进一步可通过解

$$R_1 w = \lambda R_2 w \quad (5)$$

得到一组特征向量 $\{w_j\}$ 和对应特征值 $\{\lambda_j\}$ 。这里， λ_j 越大，说明该方向上类别 1 的信号方差越大、类别 2 的方差越小；反之亦然。

最终，取最大若干个和最小若干个特征值对应的特征向量（通常各取 $M/2$ 个）构成 W ，将原始多通道 EEG 信号映射为 M 维特征：

$$X_{\text{CSP}} = W^T X.$$

在本研究中，我们将每个空间滤波后的通道功率（或对数功率）作为最终特征送入分类器。

2.1.5 高斯核支持向量机 (SVM)

在 CSP 提取的特征空间上，我们选择使用带高斯核的支持向量机进行二分类 [1]：

$$K(x, x') = \exp(-\gamma \|x - x'\|^2),$$

并通过软间隔最优化求解：

$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_i \xi_i \quad \text{s.t.} \quad y_i (w^T \phi(x_i) + b) \geq 1 - \xi_i, \quad \xi_i \geq 0.$$

2.1.6 模型集成

为降低单一模型的误差波动，我们借鉴 Bagging 思想，将 4 个 LOSO (Leave-One-Subject-Out) 模型与 1 个全量训练模型的预测结果进行多数表决集成，从而提升整体分类的稳健性。

2.2 深度学习方法

本研究采用 EEGNet，一种针对 EEG 信号的紧凑型卷积神经网络。作为深度学习模型 [4]。EEGNet 可被应用于多种 BCI 范式，对有限数据集具有较好泛化能力，且生成的特征具有神经生理可解释性。

图 1 中展示了 EEGNet 的整体结构，它主要由两个卷积模块 (Block) 构成：

Block 1: 时空滤波

首先使用 F_1 个时域卷积滤波器，核大小为 (1, 64)，长度取采样率一半（本实验采样率 250 Hz，核长 128），用于提

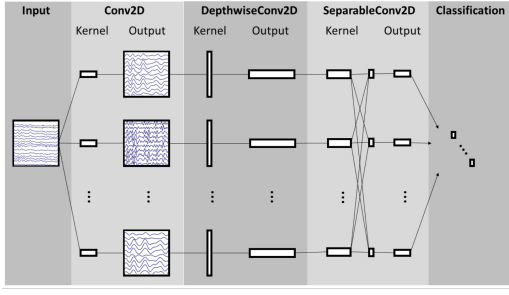


图 1: EEGNet 网络架构示意图

取不同频段下的时序特征。随后进行深度卷积 (Depthwise Convolution), 核大小 $(C, 1)$, 其中 C 为通道数, 参数 D 控制每个时序滤波器对应学习的空间滤波器数量 (图中 $D = 1$)。该两步卷积未使用激活函数, 以减少非线性带来的性能波动, 接着施加批量归一化、ELU 激活与 Dropout (跨被试分类时 $p = 0.25$), 并用 $(1, 4)$ 的平均池化将采样率降至 32 Hz。最后, 通过最大范数约束 ($\|w\|_2 \leq 1$) 对空间滤波器进行正则化。

Block 2: 可分离卷积

使用可分离卷积 (Separable Convolution) 分两步完成: 首先对每个时序特征图进行深度卷积, 核大小 $(1, 16)$ (相当于 500 ms 的 EEG 活动), 再通过 F_2 个点卷积 $((1, 1))$ 融合输出。该设计显式解耦了“特征图内”与“特征图间”的学习过程, 适合捕捉 EEG 在不同时间尺度上的信息。之后再施加批量归一化、ELU、Dropout 及 $(1, 8)$ 平均池化以进一步降维。

网络最后接全局平均池化与 Softmax 分类层。训练时使用交叉熵损失:

$$\mathcal{L} = - \sum_{i=1}^K y_i \log \hat{y}_i.$$

本课设数据量有限, EEGNet 的轻量化设计 (深度可分离卷积、较少可训练参数) 能够在小样本条件下完成有效训练, 因而成为本研究的首选深度模型。但最后由于深度学习的严重过拟合以及结果的不稳定, 我们最后选择传统机器学习方法作为我们的最终方法。

3 实验

3.1 机器学习部分

本实验在跨被试场景下, 采用四折 LOSO 验证。所有方法都基于以下统一预处理和超参数设置: 带通滤波 (Band-

pass Filter, BP) 8–16 Hz; 裁剪时间窗 (Cropping Range, CR) 0–1.5 s; 欧式对齐 (Euclidean Alignment, EA); 共空间模式 (Common Spatial Pattern, CSP) 提取空间特征, 取 $n_{\text{components}} = 4$, 正则化方式为 Ledoit–Wolf, 输出对数平均功率。

3.1.1 实验结果

表 1 比较了四种不同管道在四折验证上的准确率。

表 1: 传统机器学习方法四折验证准确率

方法	Fold1	Fold2	Fold3	Fold4	Avg
CSP+SVM	0.59	0.65	0.49	0.48	0.53
添加 EA	0.64	0.66	0.51	0.44	0.56
添加 BP	0.78	0.68	0.56	0.52	0.63
添加采样点选择	0.78	0.77	0.60	0.61	0.69

由表可见, 单纯的 CSP + SVM 基线方法平均准确率仅为 0.53; 加入带通滤波和 EA 后, 性能提升到 0.63; 进一步添加采样点选择 (CR) 后, 平均准确率提升到 0.69。因此, 本研究最终选用 BP + CR + EA + CSP + SVM 作为传统机器学习的最佳方案。

3.1.2 最终预测 (集成模型)

借鉴 Bagging 思想, 我们将以上四折 LOSO 模型与一个使用全部被试数据训练的模型进行多数表决集成, 共计 5 个基模型, 以进一步降低单一模型的波动误差并提升总体稳健性。

3.2 深度学习部分

本研究采用四折 LOSO (Leave-One-Subject-Out) 交叉验证策略。在每折中, 我们使用三位被试的全部数据训练 EEGNet, 并在剩余一位被试上验证其性能。

关键训练参数如下: 批量大小为 32, 训练周期上限为 50 个 epoch, 初始学习率设为 1×10^{-3} , 权重衰减为 1×10^{-4} ; 损失函数使用交叉熵, 优化器为 Adam, 配合 ReduceLROnPlateau 调度器 (当验证准确率连续 3 个 epoch 无提升时, 学习率乘以 0.5) 及提前停止机制 (patience=5)。

实验结果如表 2 所示, 比较了加入 EA 与未加入 EA 两种预处理下的四折验证准确率。

图 2 展示了四折训练过程中在验证集上的 Loss 曲线。可以看到, 第一、二折的 Loss 随训练稳定下降, 而第三、四折的 Loss 降幅有限, 甚至出现上升趋势, 反映出模型在后两折中存在训练不稳定和过拟合问题。

表 2: EEGNet 四折交叉验证准确率

方法	Fold1	Fold2	Fold3	Fold4	Average
EEGNet	0.520	0.535	0.620	0.505	0.545
EEGNet+EA	0.775	0.680	0.565	0.575	0.649




图 2: 四折交叉验证中各折的验证集 Loss 曲线

综上, 虽然在加入 EA 后 EEGNet 的平均准确率有所提升, 但由于部分折次出现明显的过拟合和收敛不稳定, 加之数据量有限, 深度学习模型在跨被试场景中难以保持稳定性能, 因此本研究最终未将其作为首选方法。

4 总结

本研究在跨被试运动想象 EEG 分类任务中对比了深度学习和传统机器学习两种思路。首先尝试了轻量化的 EEGNet 模型, 借助深度可分离卷积和神经生理可解释的设计, 在有限数据和四折 LOSO 验证中取得平均准确率约 0.77。但在部分折次出现了验证 Loss 不降反升、早停失效等过拟合与训练不稳定现象, 难以保证一致的跨被试性能。

随后我们基于 CSP + 线性 SVM 的传统管道, 先后引入公共平均参考 (EA)、8–16 Hz 带通滤波 (BP) 和视觉提示后 0–1.5 s 的裁剪 (CR), 每一步都明显提升了验证准确率, 从最初的 0.53 上升到最终的 **0.69**。该管道简单高效, 且在各折次表现更为稳定。

综合考虑模型的稳定性、可解释性和实现复杂度, 本研究最终选定 BP + CR + EA + CSP + SVM 作为跨被试运动想象分类的最优方案。同时, 借助 Bagging 思想对 5 个基模型进行集成, 进一步降低了单一模型的误差波动。

未来可在以下方向继续改进:

- 增加更多数据处理或数据增强方法, 以缓解数据量不足带来的过拟合风险, 同时减少噪声的影响;
- 探索其他空间滤波和特征融合策略, 如 Riemannian 方法或多频段 CSP;

参考文献

- [1] C. Cortes and V. Vapnik. Support-vector networks. *Machine Learning*, 20:273–297, 1995.
- [2] He He and Dongrui Wu. Transfer learning for brain-computer interfaces: A euclidean space data alignment approach. *IEEE Transactions on Biomedical Engineering*, 67(2):399–410, 2020.
- [3] Z. J. Koles, M. S. Lazar, and S. Z. Zhou. Spatial patterns underlying population differences in the background eeg. *Brain Topography*, 2:275–284, 1990.
- [4] Vernon J Lawhern, Amelia J Solon, Nicholas R Waytowich, Stephen M Gordon, Chou P Hung, and Brent J Lance. Eegnet: a compact convolutional neural network for eeg-based brain-computer interfaces. *Journal of Neural Engineering*, 15(5):056013, July 2018.