

## Lecture7-8 作业

1 , 假设两个样本  $\{(\vec{V}_1, y_1) = ((v_1, v_2)^T, 1), (\vec{V}_2, y_2) = ((-v_1, -v_2)^T, -1)\}$ , 假设 H 是这两个样本的最大间隔分类面, 写出其表达式。

解: 两个样本关于原点对称, 最大间隔分类面会垂直于两个样本的连线, 且穿过原点, 即样本连线的斜率与分类面 (分类线) 斜率的乘积为 -1, 而样本连线的斜率为  $\frac{v_2}{v_1}$ , 所以, 分类面 (线) 的斜率为:  $-\frac{v_1}{v_2}$ , 且  $b=0$ 。

所以, 最大间隔分类面为:

$$x_2 = -\frac{v_1}{v_2} x_1$$

$$\text{即: } v_1 x_1 + v_2 x_2 = 0$$

2 , 假设三个样本为  $D = \{(\vec{x}_1, y_1) = ((3, 0)^T, 1), (\vec{x}_2, y_2) = ((0, 4)^T, 1), (\vec{x}_3, y_3) = ((0, 0)^T, -1)\}$ , 计算这三个样本到平面:  $x_1 + x_2 = 1$  的距离。

解:  $d = \frac{|\vec{w}^T \vec{x} + b|}{\|\vec{w}\|}$

$$x_1 + x_2 = 1 \rightarrow x_1 + x_2 - 1 = 0$$

$$d_1 = \frac{|\vec{w}^T \vec{x}_1 + b|}{\|\vec{w}\|} = \frac{|(1, 1) \begin{pmatrix} 3 \\ 0 \end{pmatrix} - 1|}{\sqrt{(1^2 + 1^2)}} = \sqrt{2}$$

$$d_2 = \frac{|\vec{w}^T \vec{x}_2 + b|}{\|\vec{w}\|} = \frac{|(1, 1) \begin{pmatrix} 0 \\ 4 \end{pmatrix} - 1|}{\sqrt{(1^2 + 1^2)}} = \frac{3}{2} \sqrt{2}$$

$$d_3 = \frac{|\vec{w}^T \vec{x}_3 + b|}{\|\vec{w}\|} = \frac{|(1,1) \begin{pmatrix} 0 \\ 0 \end{pmatrix} - 1|}{\sqrt{1^2 + 1^2}} = \frac{\sqrt{2}}{2}$$

3, 假设训练样本集为  $D = \{(\vec{x}_1, y_1) = ((0,0)^T, -1), (\vec{x}_2, y_2) = ((2,2)^T, -1), (\vec{x}_3, y_3) = ((2,0)^T, 1), (\vec{x}_4, y_4) = ((3,0)^T, 1)\}$ , 使用QP求解器时,  $\vec{a}_n^T (n=1,2,3,4)$  分别为多少?

解:  $\vec{a}_1^T = (-1, 0, 0)$ ,  $\vec{a}_2^T = (-1, -2, -2)$ ,  $\vec{a}_3^T = (1, 2, 0)$ ,  $\vec{a}_4^T = (1, 3, 0)$

4, 假设训练样本集为:  $D = \{(\vec{x}_1, y_1) = ((1,1)^T, 1), (\vec{x}_2, y_2) = ((2,2)^T, 1), (\vec{x}_3, y_3) = ((2,0)^T, 1), (\vec{x}_4, y_4) = ((0,0)^T, -1), (\vec{x}_5, y_5) = ((1,0)^T, -1), (\vec{x}_6, y_6) = ((0,1)^T, -1)\}$ , 请分别在  $y_n(\vec{w}^T \vec{x}_n + b) \geq 1$  和  $y_n(\vec{w}^T \vec{x}_n + b) \geq 5$  的条件下用 Primal SVM 方法来设计最优分类面  $g(\vec{x})$ , 判断两种情况下的分类面是否一致, 指出哪些是候选的支撑向量, 并回答如何确认哪些是支撑向量。

解: (1) 对于条件  $y_n(\vec{w}^T \vec{x}_n + b) \geq 1$ , 可列出如下的式子

$$\begin{aligned} \min_{b, w} & \frac{1}{2} \mathbf{w}^T \mathbf{w} \\ \text{s.t.} & \begin{cases} w_1 + w_2 + b \geq 1 \\ 2w_1 + 2w_2 + b \geq 1 \\ 2w_1 + b \geq 1 \\ -b \geq 1 \\ -w_1 - b \geq 1 \\ -w_2 - b \geq 1 \end{cases} \implies \begin{cases} w_1 \geq 2 \\ w_2 \geq 2 \\ b \leq -3 \end{cases} \end{aligned}$$

当且仅当  $w_1 = 2, w_2 = 2, b = -3$ ,

$$\frac{1}{2} \mathbf{w}^T \mathbf{w} = \frac{1}{2} (w_1^2 + w_2^2) \geq \frac{1}{2} (2^2 + 2^2) = 4 \text{ 取得最小值。}$$

可以验证 constraints 均满足。

故此时的最优分类面为

$$\mathbf{w}_1^T \mathbf{x} + b_1 = 0$$

其中  $\mathbf{w}_1 = [2 \ 2]^T, b_1 = -3$ 。

可以验证, 将  $\mathbf{w}_1 = [2 \ 2]^T, b_1 = -3$  代入上述 constraints 中有第 1、3、

5、6 是严格等式, 故候选支撑向量为  $\mathbf{x}_1, \mathbf{x}_3, \mathbf{x}_5, \mathbf{x}_6$ 。

由 Dual SVM 知识可知, 当求解 Dual SVM 问题时, 在如下式子中

$$\alpha_n (1 - y_n (\mathbf{w}^T \mathbf{x}_n + b)) = 0$$

$\mathbf{x}_1, \mathbf{x}_3, \mathbf{x}_5, \mathbf{x}_6$  满足  $\alpha_n > 0, y_n (\mathbf{w}^T \mathbf{x}_n + b) = 1$  所对应的样本即为支撑向量。

(2) 对于条件  $y_n (\vec{w}^T \vec{x}_n + b) \geq 5$ , 可列出如下的式子

$$\begin{aligned} \min_{b, \mathbf{w}} \quad & \frac{1}{2} \mathbf{w}^T \mathbf{w} \\ \text{s.t.} \quad & \begin{cases} w_1 + w_2 + b \geq 5 \\ 2w_1 + 2w_2 + b \geq 5 \\ 2w_1 + b \geq 5 \\ -b \geq 5 \\ -w_1 - b \geq 5 \\ -w_2 - b \geq 5 \end{cases} \implies \begin{cases} w_1 \geq 10 \\ w_2 \geq 10 \\ b \leq -15 \end{cases} \end{aligned}$$

当且仅当  $w_1 = 10, w_2 = 10, b = -15$  时有

$$\frac{1}{2} \mathbf{w}^T \mathbf{w} = \frac{1}{2} (w_1^2 + w_2^2) \geq \frac{1}{2} (10^2 + 10^2) = 100 \text{ 取得最小值,}$$

可以验证 constraints 均满足。

故此时的最优分类面为

$$\mathbf{w}_2^T \mathbf{x} + b_2 = 0, \text{ which is exactly equivalent to } \mathbf{w}_1^T \mathbf{x} + b_1 = 0$$

其中  $\mathbf{w}_2 = [10 \ 10]^T, b_2 = -15$ 。

可以验证, 将  $\mathbf{w}_2 = [10 \ 10]^T, b_2 = -15$  代入上述 constraints 中有第 1、3、5、6 是严格等式, 故候选支撑向量为  $\mathbf{x}_1, \mathbf{x}_3, \mathbf{x}_5, \mathbf{x}_6$ 。

由 Dual SVM 知识可知, 当求解 Dual SVM 问题时, 在如下式子中

$$\alpha_n (1 - y_n (\mathbf{w}^T \mathbf{x}_n + b)) = 0$$

$\mathbf{x}_1, \mathbf{x}_3, \mathbf{x}_5, \mathbf{x}_6$  满足  $\alpha_n > 0, y_n (\mathbf{w}^T \mathbf{x}_n + b) = 5$  所对应的样本即为支撑向量。

5, Hinge Loss 是支撑向量机的误差函数, 因此, 除了用二次规划求解最佳分类面外, 也能用梯度下降法求解, (1) 请推导梯度并写出算法流程; (2) 假设初始增广权向量  $\vec{w} = (0, 0, 0)^T$ , 用第 4 题训练样本集去设计分类面, 指出哪些向量在边界上? 假设它们都是支撑向量的话, 请问最佳权系数向量是否是这些支撑向量的线性组合?

解: (1) 已知样本集合  $\{(\vec{x}_1, y_1), (\vec{x}_2, y_2), \dots, (\vec{x}_N, y_N)\}$ , 每个样本的标签为  $y_n \in \{+1, -1\}$ , 我们基于 Hinge Loss, 对于每个样本定义其误差函数为:

$$err_{SVM} = \max(0, 1 - y_n (\vec{w}^T \vec{x}_n + b))$$

对其求梯度, 得到:

$$\text{当 } 1 - y_n (\vec{w}^T \vec{x}_n + b) \geq 0, \quad \frac{\partial E_{in}(\vec{w})}{\partial \vec{w}} = -y_n \vec{x}_n$$

$$\text{当 } 1 - y_n (\vec{w}^T \vec{x}_n + b) < 0, \quad \frac{\partial E_{in}(\vec{w})}{\partial \vec{w}} = 0$$

利用随机梯度下降法得到新的 $\vec{w}$

$$\vec{w}^{(t+1)} = \vec{w}^{(t)} - \eta \frac{\partial E_{in}(\vec{w}^{(t)})}{\partial \vec{w}^{(t)}} = \vec{w}^{(t)} + \eta \llbracket 1 - y_n(\vec{w}^T \vec{x}_n + b) \geq 0 \rrbracket y_n \vec{x}_n$$

$$\text{其中, } \llbracket \cdot \rrbracket = \begin{cases} 1, & \text{if condition is satisfied} \\ 0, & \text{otherwise} \end{cases}$$

(2) 初始增广权向量 $\vec{w}^{(0)} = (0,0,0)^T$

$$\vec{x}_1 = (1,1,1)^T, \vec{x}_2 = (1,2,2)^T, \vec{x}_3 = (1,2,0)^T,$$

$$\vec{x}_4 = (1,0,0)^T, \vec{x}_5 = (1,1,0)^T, \vec{x}_6 = (1,0,1)^T$$

$$y_1 = 1, y_2 = 1, y_3 = 1, y_4 = -1, y_5 = -1, y_6 = -1$$

取学习率 $\eta = 1$

第一轮迭代

$$\max(0, 1 - y_1(\vec{w}^{(0)T} \vec{x}_1)) = \max(0, 1) = 1$$

$$\frac{\partial E_{in}(\vec{w}^{(0)})}{\partial \vec{w}^{(0)}} = -y_1 \vec{x}_1 = (-1, -1, -1)^T$$

$$\vec{w}^{(1)} = \vec{w}^{(0)} - \eta \frac{\partial E_{in}(\vec{w}^{(1)})}{\partial \vec{w}^{(1)}} = \vec{w}^{(0)} + y_1 \vec{x}_1 = (1, 1, 1)^T$$

第二轮迭代

$$\max(0, 1 - y_2(\vec{w}^{(1)T} \vec{x}_2)) = \max(0, -4) = 0$$

$$\vec{w}^{(2)} = \vec{w}^{(1)} = (1, 1, 1)^T$$

第三轮迭代

$$\max(0, 1 - y_3(\vec{w}^{(2)T} \vec{x}_3)) = \max(0, -2) = 0$$

$$\vec{w}^{(3)} = \vec{w}^{(2)} = (1, 1, 1)^T$$

第四轮迭代

---


$$\max\left(0, 1 - y_4 \left(\vec{w}^{(3)T} \vec{x}_4\right)\right) = \max(0, 2) = 2$$

$$\frac{\partial E_{in}(\vec{w}^{(3)})}{\partial \vec{w}^{(3)}} = -y_4 \vec{x}_4 = (1, 0, 0)^T$$

$$\vec{w}^{(4)} = \vec{w}^{(3)} + y_4 \vec{x}_4 = (0, 1, 1)^T$$

第五轮迭代

$$\max\left(0, 1 - y_5 \left(\vec{w}^{(4)T} \vec{x}_5\right)\right) = \max(0, 2) = 2$$

$$\frac{\partial E_{in}(\vec{w}^{(4)})}{\partial \vec{w}^{(4)}} = -y_5 \vec{x}_5 = (1, 1, 0)^T$$

$$\vec{w}^{(5)} = \vec{w}^{(4)} + y_5 \vec{x}_5 = (-1, 0, 1)^T$$

第六轮迭代

$$\max\left(0, 1 - y_6 \left(\vec{w}^{(5)T} \vec{x}_6\right)\right) = \max(0, 1) = 1$$

$$\frac{\partial E_{in}(\vec{w}^{(5)})}{\partial \vec{w}^{(5)}} = -y_6 \vec{x}_6 = (1, 0, 1)^T$$

$$\vec{w}^{(6)} = \vec{w}^{(5)} + y_6 \vec{x}_6 = (-2, 0, 0)^T$$

第七轮迭代

$$\max\left(0, 1 - y_1 \left(\vec{w}^{(6)T} \vec{x}_1\right)\right) = \max(0, 3) = 3$$

$$\frac{\partial E_{in}(\vec{w}^{(7)})}{\partial \vec{w}^{(7)}} = -y_1 \vec{x}_1 = (-1, -1, -1)^T$$

$$\vec{w}^{(7)} = \vec{w}^{(6)} + y_1 \vec{x}_1 = (-1, 1, 1)^T$$

第八轮迭代

$$\max\left(0, 1 - y_2 \left(\vec{w}^{(7)T} \vec{x}_2\right)\right) = \max(0, -2) = 0$$

$$\vec{w}^{(8)} = \vec{w}^{(7)} = (-1, 1, 1)^T$$

第九轮迭代

$$\max\left(0, 1 - y_3 \left(\vec{w}^{(8)T} \vec{x}_3\right)\right) = \max(0, 0) = 0$$

$$\frac{\partial E_{in}(\vec{w}^{(8)})}{\partial \vec{w}^{(8)}} = -y_3 \vec{x}_3 = (-1, -2, 0)^T$$

$$\vec{w}^{(9)} = \vec{w}^{(8)} + y_3 \vec{x}_3 = (0, 3, 1)^T$$

第十轮迭代

$$\max\left(0, 1 - y_4 \left(\vec{w}^{(9)T} \vec{x}_4\right)\right) = \max(0, 1) = 1$$

$$\frac{\partial E_{in}(\vec{w}^{(9)})}{\partial \vec{w}^{(9)}} = -y_4 \vec{x}_4 = (1, 0, 0)^T$$

$$\vec{w}^{(10)} = \vec{w}^{(9)} + y_4 \vec{x}_4 = (-1, 3, 1)^T$$

第十一轮迭代

$$\max\left(0, 1 - y_5 \left(\vec{w}^{(10)T} \vec{x}_5\right)\right) = \max(0, 1) = 1$$

$$\frac{\partial E_{in}(\vec{w}^{(4)})}{\partial \vec{w}^{(4)}} = -y_5 \vec{x}_5 = (1, 1, 0)^T$$

$$\vec{w}^{(11)} = \vec{w}^{(10)} + y_5 \vec{x}_5 = (-2, 2, 1)^T$$

第十二轮迭代

$$\max\left(0, 1 - y_6 \left(\vec{w}^{(11)T} \vec{x}_6\right)\right) = \max(0, 0) = 0$$

$$\frac{\partial E_{in}(\vec{w}^{(11)})}{\partial \vec{w}^{(11)}} = -y_6 \vec{x}_6 = (1, 0, 1)^T$$

$$\vec{w}^{(12)} = \vec{w}^{(11)} + y_6 \vec{x}_6 = (-3, 2, 0)^T$$

第十三轮迭代

$$\max\left(0, 1 - y_1 \left(\vec{w}^{(12)T} \vec{x}_1\right)\right) = \max(0, 2) = 2$$

$$\frac{\partial E_{in}(\vec{w}^{(12)})}{\partial \vec{w}^{(12)}} = -y_1 \vec{x}_1 = (-1, -1, -1)^T$$

$$\vec{w}^{(7)} = \vec{w}^{(6)} + y_1 \vec{x}_1 = (-2, 3, 1)^T$$

第十四轮迭代

对于  $\vec{x}_2$ 、 $\vec{x}_3$ 、 $\vec{x}_4$  满足  $1 - y_n (\vec{w}^{(13)^T} \vec{x}_n) < 0$

$$\max(0, 1 - y_5 (\vec{w}^{(13)^T} \vec{x}_5)) = \max(0, 2) = 2$$

$$\vec{w}^{(14)} = \vec{w}^{(13)} + y_5 \vec{x}_5 = (-3, 2, 1)^T$$

第十五轮迭代

对于  $\vec{x}_6$  满足  $1 - y_n (\vec{w}^{(13)^T} \vec{x}_n) < 0$

$$\max(0, 1 - y_1 (\vec{w}^{(14)^T} \vec{x}_1)) = \max(0, 1) = 1$$

$$\vec{w}^{(15)} = \vec{w}^{(14)} + y_1 \vec{x}_1 = (-2, 3, 2)^T$$

第十六轮迭代

对于  $\vec{x}_2$ 、 $\vec{x}_3$ 、 $\vec{x}_4$  满足  $1 - y_n (\vec{w}^{(15)^T} \vec{x}_n) < 0$

$$\max(0, 1 - y_5 (\vec{w}^{(15)^T} \vec{x}_5)) = \max(0, 2) = 2$$

$$\vec{w}^{(16)} = \vec{w}^{(15)} + y_5 \vec{x}_5 = (-3, 2, 2)^T$$

检验对任意  $\vec{x}_n$  满足  $1 - y_n (\vec{w}^{(15)^T} \vec{x}_n) < 0$ ，迭代结束

得到分类面为  $2x_1 + 2x_2 - 3 = 0$

$$\vec{w} = (-3, 2, 2)^T$$

将  $x_1$ 、 $x_3$ 、 $x_5$ 、 $x_6$  代入  $1 - y_n (\vec{w}^T \vec{x}_n + b)$  均为 0，

说明这四个样本在边界上，均为候选的支撑向量。

为简单起见（不用求解对偶 SVM），按照本题题意候选的支撑向量均

为支撑向量，则： $\vec{w} = 7x_1 + 0x_3 - 5x_5 - 5x_6$ ，即最佳权系数向量为

支撑向量的线性组合。



6, 假如做了非线性变换后的两个训练样本为:  $\{(\vec{Z}_1, +1) = (\vec{z}, 1), (\vec{Z}_2, -1) = (-\vec{z}, -1)\}$ , 请写出用于设计硬间隔 SVM 时的拉格朗日函数  $L(\vec{w}, b, \alpha)$ 。

解: 根据定义:

$$L(\vec{w}, b, \alpha) = \frac{1}{2} \vec{w}^T \vec{w} + \alpha_1 (1 - y_1 (\vec{w}^T \vec{z}_1 + b)) + \alpha_2 (1 - y_2 (\vec{w}^T \vec{z}_2 + b))$$

将两个样本代入, 得到:

$$L(\vec{w}, b, \alpha) = \frac{1}{2} \vec{w}^T \vec{w} + \alpha_1 (1 - (\vec{w}^T \vec{z} + b)) + \alpha_2 (1 + (-\vec{w}^T \vec{z} + b))$$

7, 对于一个单变量  $w$ , 假设要在  $w \geq 1$  和  $w \leq 3$  这两个线性约束条件下, 求  $\frac{1}{2} w^2$  的最小值, 请写出其拉格朗日函数  $L(w, \alpha)$  以及这个最优问题的 KKT 条件。

解: 由于是单变量, 根据定义及约束条件:

$$L(w, \alpha) = \frac{1}{2} w^2 + \alpha_1 (1 - w) + \alpha_2 (w - 3)$$

KKT 条件为:

$$\alpha_1 \geq 0, \alpha_2 \geq 0,$$

$$w = \alpha_1 - \alpha_2, \text{ (通过 } \frac{\partial L(w, \alpha)}{\partial w} = 0 \text{ 得到)}$$

$$\alpha_1 (1 - w) = 0, \alpha_2 (w - 3) = 0.$$

8, 假如做了非线性变换后的两个训练样本为:  $\{(\vec{Z}_1, +1) = (\vec{z}, 1), (\vec{Z}_2, -1) = (-\vec{z}, -1)\}$ , 在求解硬间隔 SVM 的对偶问题时, 假定得到的最佳  $\alpha_1 > 0$ , 最佳  $\alpha_2 > 0$ , 请问最佳  $b$  为多少?

解：由于 $\alpha_1 > 0$ ,  $\alpha_2 > 0$ , 所以： $\vec{Z}_1$ 和 $\vec{Z}_2$ 为支撑向量，根据定义：

$$b = y_1 - \vec{w}^T \vec{Z}_1 = y_2 - \vec{w}^T \vec{Z}_2 = 1 - \vec{w}^T \vec{Z} = -1 + \vec{w}^T \vec{Z}$$

得到： $\vec{w}^T \vec{Z} = 1$ ,  $b = 0$

9, 假设有 5566 个样本用以训练对偶硬间隔 SVM 时得到 1126 个支撑向量，请问落在分类面边界上的样本数（也就是候选的支撑向量）有可能是：（a）0；（b）1024；（c）1234；（d）9999。

解： 因为：支撑向量数 $\leq$ 候选的支撑向量数 $\leq$ 样本总数

所以选择（c）

10, 如果两个样本 $\vec{x}$ 和 $\vec{x}'$ 的内积 $\vec{x}^T \vec{x}' = 10$ , 计算其 $\phi_2$ 核函数 $K_{\phi_2}(\vec{x}, \vec{x}')$ 等于多少？

解：因为： $K_{\phi_2}(\vec{x}, \vec{x}') = 1 + \vec{x}^T \vec{x}' + (\vec{x}^T \vec{x}')^2$

所以： $K_{\phi_2}(\vec{x}, \vec{x}') = 1 + 10 + 100 = 111$

11, 假设训练样本集为： $D = \{(\vec{x}_1, y_1) = ((1,0)^T, 1), (\vec{x}_2, y_2) = ((-1,0)^T, 1), (\vec{x}_3, y_3) = ((0,1)^T, -1), (\vec{x}_4, y_4) = ((0,-1)^T, -1)\}$ , 请用 Dual SVM 来设计最优分类面 $g(\vec{x})$ , 并指出哪些是支撑向量。

解：样本为非线性分布，所以，需要首先进行非线性变换：

$$\text{令 } \phi_2(\vec{x}) = \{1, x_1, x_2, x_1 x_2, x_1^2, x_2^2\}$$

$$\text{则: } (\vec{x}_1, y_1) \rightarrow (\vec{z}_1, y_1): \{(1,0)^T, 1\} \rightarrow \{(1,1,0,0,1,0)^T, 1\}$$

$$(\vec{x}_2, y_2) \rightarrow (\vec{z}_2, y_2): \{(-1,0)^T, 1\} \rightarrow \{(1,-1,0,0,1,0)^T, 1\}$$

$$(\vec{x}_3, y_3) \rightarrow (\vec{z}_3, y_3): \{(0,1)^T, -1\} \rightarrow \{(1,0,1,0,0,1)^T, -1\}$$

$$(\vec{x}_4, y_4) \rightarrow (\vec{z}_4, y_4): \{(0,-1)^T, -1\} \rightarrow \{(1,0,-1,0,0,1)^T, -1\}$$

$$\text{令 } \alpha_1 \geq 0, \alpha_2 \geq 0, \alpha_3 \geq 0, \alpha_4 \geq 0$$

由 SVM 对偶模型得到：

$$\begin{cases} L(\vec{w}, b, \alpha) = \frac{1}{2} \sum_{n=1}^4 \sum_{m=1}^4 \alpha_n \alpha_m y_n y_m \vec{z}_n^T \vec{z}_m - \sum_{n=1}^4 \alpha_n \\ \sum_{n=1}^4 y_n \alpha_n = 0 \end{cases}$$

$$\text{求 } L(\vec{w}, b, \alpha) \text{ 对 } \alpha \text{ 的梯度: } \frac{\partial L}{\partial \alpha_n} = \sum_{m=1}^4 \alpha_m y_n y_m \vec{z}_n^T \vec{z}_m - 1$$

$$\text{且: } \alpha_1 + \alpha_2 - \alpha_3 - \alpha_4 = 0$$

代入训练样本，

$$\frac{\partial L}{\partial \alpha_1} = 3\alpha_1 + \alpha_2 - \alpha_3 - \alpha_4 - 1 = 0 \rightarrow 2\alpha_1 - 1 = 0$$

$$\frac{\partial L}{\partial \alpha_2} = 3\alpha_2 + \alpha_1 - \alpha_3 - \alpha_4 - 1 = 0 \rightarrow 2\alpha_2 - 1 = 0$$

$$\frac{\partial L}{\partial \alpha_3} = 3\alpha_3 - \alpha_1 - \alpha_2 + \alpha_4 - 1 = 0 \rightarrow 2\alpha_3 - 1 = 0$$

$$\frac{\partial L}{\partial \alpha_4} = \alpha_4 - \alpha_1 - \alpha_2 + \alpha_3 - 1 = 0 \rightarrow 2\alpha_4 - 1 = 0$$

$$\text{求解得到: } \alpha_1 = \alpha_2 = \alpha_3 = \alpha_4 = \frac{1}{2}$$

$$\therefore \vec{w} = \sum_{n=1}^4 \alpha_n y_n \vec{z}_n = \frac{1}{2} (\vec{z}_1 + \vec{z}_2 - \vec{z}_3 - \vec{z}_4) = (0,0,0,0,1,-1)^T$$

$$b = y_1 - \vec{w}^T \vec{z}_1 = 1 - (0,0,0,0,1,-1)(1,1,0,0,1,0)^T = 0$$

$$\therefore g_{SVM} = \text{sign}(\vec{w}^T \phi_2(\vec{x}) + b) = \text{sign}(x_1^2 - x_2^2)$$

且四个样本均为支撑向量。