

Lecture10-11 作业

1, 假设 $g_0(\vec{x}) = 1$, 以下哪一组 $(\alpha_0, \alpha_1, \alpha_2)$ 允许 $G(\vec{x}) = \text{sign}(\sum_{t=0}^2 \alpha_t g_t(\vec{x}))$ 实现 $OR(g_1, g_2)$ 的功能。(a) $(-3, +1, +1)$; (b) $(-1, +1, +1)$; (c) $(+1, +1, +1)$; (d) $(+3, +1, +1)$ 。

解: $OR(g_1, g_2)$ 的关系意味着只要有一个 $g_i = 1$, 输出即为 1, 当两个都为 “-1” 时, 输出才为 -1。

根据题目条件:

(a) $G(\vec{x}) = \text{sign}(-3 + g_1(\vec{x}) + g_2(\vec{x}))$, 当 $g_1(\vec{x}) = g_2(\vec{x}) = 1$ 时, $G(\vec{x}) = -1$, 不满足定义;

(b) $G(\vec{x}) = \text{sign}(-1 + g_1(\vec{x}) + g_2(\vec{x}))$, 当 $g_1(\vec{x}) = -1, g_2(\vec{x}) = 1$, 或者 $g_1(\vec{x}) = 1, g_2(\vec{x}) = -1$ 时, $G(\vec{x}) = -1$, 不满足定义;

(c) $G(\vec{x}) = \text{sign}(1 + g_1(\vec{x}) + g_2(\vec{x}))$, $g_1(\vec{x})$ 与 $g_2(\vec{x})$ 取任意的 +1 和 -1 时, 均能满足 $OR(g_1, g_2)$ 的定义;

(d) $G(\vec{x}) = \text{sign}(3 + g_1(\vec{x}) + g_2(\vec{x}))$, 当 $g_1(\vec{x}) = g_2(\vec{x}) = -1$ 时, $G(\vec{x}) = 1$, 不满足定义。


所以, 只有(c)满足定义。

2, 在 3-5-1 的神经网络中, 网络参数有多少?

解: 在第一层 3-5 中的参数为: $(3+1 \text{ (常数项)}) * 5 = 20$; 在第二层 5-1 中的参数为 $(5+1 \text{ (常数项)}) * 1 = 6$, 所以, 网络参数一共为 26。

3, 画出 $(x+y)^2 z$ 的计算图, 当 $x=1, y=2, z=-6$ 时, 写出前向传播的数值和反向传播的梯度值。

解:

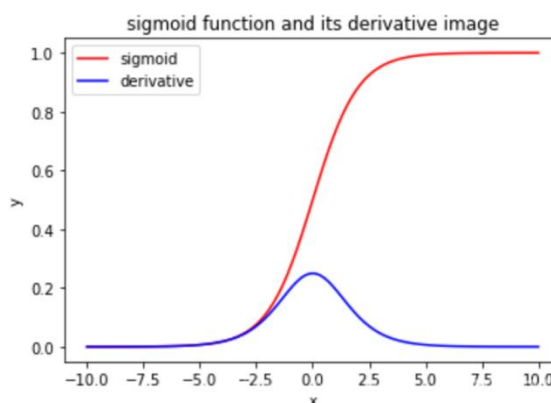


4, 计算 Sigmoid 函数、双曲正切函数和 ReLU 函数的导数函数, 分析这三个函数作为激活函数时的优缺点。

解: (1) 对于 Sigmoid 函数, $\theta(x) = \frac{1}{1+e^{-x}}$

$$\frac{\partial \theta(x)}{\partial x} = \frac{e^{-x}}{(1+e^{-x})^2} = \frac{1+e^{-x}-1}{1+e^{-x}} \cdot \frac{1}{1+e^{-x}} = (1-\theta(x))\theta(x)$$

Sigmoid 函数作为激活函数的优点是连续、单调、可导且具有非线性特点。但其缺点是非中心对称, 输出不是 0 均值的, 同时它的导数函数曲线见右图, x 变化很小的范围内, 导数才有值且不大, 在神经




网络应用中，训练过程使用的是反向传播算法，通过链式法则回传的梯度不断相乘，因此，Sigmoid 函数作为激活函数时会导致梯度消失问题，尤其在网络比较深时会达不到训练效果。

(2) 对于双曲正切函数， $\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$

$$\frac{\partial \tanh(x)}{\partial x} = \frac{(e^x + e^{-x})(e^x + e^{-x}) - (e^x - e^{-x})(e^x - e^{-x})}{(e^x + e^{-x})^2} = 1 - \tanh^2(x)$$

双曲正切函数作为激活函数的优点是中心对称、单调、连续、可导且具有非线性特点。但其缺点是它的导数函数曲线见右图， x 变化更




小的范围内，导数才有值且不大于 1，在神经网络应用中，训练过程使用的是反向传播算法，通过链式法则回传的梯度不断相乘，因此，双曲正切函数作为激活函数时同样会导致梯度消失问题，尤其在网络比较深时会达不到训练效果。

(3) 对于 ReLU 函数， $ReLU(x) = \max(0, x)$

$$\frac{\partial ReLU(x)}{\partial x} = \begin{cases} 1 & x > 0 \\ 0 & x \leq 0 \end{cases}$$

ReLU 函数作为激活函数的优点是梯度不会饱和，解决了梯度消失问题，没有指数计算，计算复杂度低。它的缺点是非中心对称，负数部分的梯度为



0，导致相应参数不会更新。

5，对于一幅 300×300 大小的彩色（RGB）图像，（1）如果输入端与有 100 个神经元的的第一层隐含层用全链接方式（Fully Connected neural Network）连接时，请问这一层会包含多少参数？（2）如果用 100 个 $5 \times 5 \times 3$ 大小的滤波器作卷积操作，那么这一层的参数为多少？如果滤波器移动步长（stride=1）为 1，经过卷积计算后的输出端神经元个数有多少？

解：（1）因为是 RGB 图像，所以共有 3 个通道，全连接情况下包含的参数是： 300×300 （图像大小） $\times 3$ （颜色通道数） $\times 100$ （第一层神经元个数） $+ 1 \times 100$ （每个神经元都要与输入层的常数项连接） $= 27000100$ ；

（2）卷积操作时，第一层的参数是由卷积滤波器大小和常数项共同确定的，因此其包含的参数为： $(5 \times 5$ （滤波器大小） $\times 3$ （颜色通道数） $+ 1$ （常数项） $) \times 100$ （滤波器个数） $= 7600$ ；（即：F=5，K=100，D1=3，参数量= $(F \times F \times D1) \times K + K = 5 \times 5 \times 3 \times 100 + 100 = 7600$ ）

因为卷积核为 $5 \times 5 \times 3$ ，且填充值为 0，卷积后第一层神经元的个数为 $((300$ （图像长或宽） $- 5$ （滤波器大小） $) / 1$ （移动步长） $) + 1$ $)^2 \times 100$ （滤波器个数） $= 8761600$ （相当于 $W1=300$ ， $H1=300$ ， $D1=3$ ， $F=5$ ， $K=100$ ， $S=1$ ， $P=0$ ， $W2 = (W1 - F + 2P) / S + 1 = (300 - 5 + 0) / 1 + 1 = 296$ ； $H2 = (H1 - F + 2P) / S + 1 = (300 - 5 + 0) / 1 + 1 = 296$ ； $D2=K=100$ ，神经元个数为： $W2 \times H2 \times D2 = 296 \times 296 \times 100 = 8761600$ ）

6, 某一个卷积神经网络结构如下:

(i) 输入层 Input 的 RGB 图像大小是 $227 \times 227 \times 3$ 。

(ii) 第 1 层卷积层 Conv-1 是通过对输入图像用 96 个 $11 \times 11 \times 3$ 大小的滤波器通过步长(stride)为 4, 不做边缘填充(padding)得到的。

(iii) 接下来是池化层 MaxPool-1, 它用 3×3 尺寸、步长为 2 对 Conv-1 做 Max Pooling 操作。

(iv) 然后我们对图像进行边缘填充, 填充值为 2 (如原来图像大小为 7×7 时, 做填充值为 2 的填充后, 图像大小变为 11×11), 用 256 个 5×5 大小的滤波器按步长为 1, 做第二次卷积操作, 得到 Conv-2 层。

(v) 再接一个池化层 MaxPool-2, 它用 3×3 尺寸、步长为 2 做一次 Max Pooling 操作。

(vi) MaxPool-2 层输出去接一个有 4096 个神经元的全连接层 FC-1。

(vii) 再接一个全连接层 FC-2 实现对 1000 个类别的分类。

请计算: (1) 输入层到 Conv-1 层的参数量有多少? (2) 经过池化层 MaxPool-1 后的神经元是多少? (3) 经过第二次卷积操作后的图像大小为多少? (4) MaxPool-2 层到 FC-1 层的参数量是多少? (5) FC-1 层到 FC-2 层的参数量是多少?

解: 输入图像大小为 $227 \times 227 \times 3$ (即: $W_1=227, H_1=227, D_1=3$), 第一层卷积核为 11×11 (即: $F=11$), 共 96 个滤波器 (即: $K=96$), 步长为 4 (即: $S=4$), 边缘填充为 0 (即: $P=0$), 则卷积以后的图像边

长为： $((227-11+2*0)/4)+1=55$ ，大小为 $55*55$ （即 $W2=H2=55$ ），与 96 个滤波器构成特征图，所以卷积层 Conv-1 的神经元个数为 $55*55*96=290400$ ，(1)输入层到 Conv-1 层的参数量为 $F*F*D1*K+1*K$ ，即： $11*11*3*96+1*96=34944$ ；对 $55*55$ 大小的图像做第一次 Maxpooling，这时候通道数 96 保持不变，因为它用 $3*3$ 大小的尺寸以步长为 2 做 Maxpooling，则得到的图像边长为 $((55-3)/2)+1=27$ ，图像大小为 $27*27$ ，(2)经过池化层 MaxPool-1 后的神经元为 $27*27*96$ ；再做第二次卷积，此时是对 $27*27$ 大小的图像，用 $5*5$ 大小的滤波器按步长为 1，边缘填充值为 2 做卷积，滤波器个数为 256 个，所以，卷积后图像的边长为 $((27-5+2*2)/1)+1=27$ ，大小为 $27*27$ ，与 256 个滤波器构成特征图，所以卷积层 Conv-2 的神经元个数为 $27*27*256=186624$ ，(3)经过第二次卷积操作后的图像大小为 $27*27$ ，MaxPool-1 层到 Conv-2 层的参数量为： $5*5*96$ （池化层的通道数）*256（滤波器个数）+256（常数项）=614656；再经过池化层 MaxPool-2， $3*3$ 尺寸、步长为 2，则得到的图像边长为 $((27-3)/2)+1=13$ ，图像大小为 $13*13$ ，上一层的通道数是 256，所以，MaxPool-2 层的神经元个数为 $13*13*256=43264$ ；MaxPool-2 层输出去接一个有 4096 个神经元的全连接层 FC-1，所以，(4) MaxPool-2 层到 FC-1 层的参数量是 $13*13*256*4096+4096$ （常数项）=177213440；最后的输出层要对 1000 个类别进行分类，即 FC-2 层的神经元个数是 1000 个，而输入是 4096 个神经元，所以，(5) FC-1 层到 FC-2 层的参数量是 $4096*1000+1000=4097000$

7, 有训练样本集为: $D = \{(\vec{x}_1, y_1) = ((1, 1)^T, 1), (\vec{x}_2, y_2) = ((-1, -1)^T, 1), (\vec{x}_3, y_3) = ((-1, 1)^T, -1), (\vec{x}_4, y_4) = ((1, -1)^T, -1)\}$,

假设某神经网络结构为第一层有两个神经元, 第二层有三个神经元, 第三层有一个神经元, 前两层每个神经元的激活函数为ReLU (即 $x_d^{(l)} = \max(0, s_d^{(l)})$, 这里 $s_d^{(l)}$ 代表第 l 层第 d 个神经元的输入, $x_d^{(l)}$ 代表该神经元的输出), 第三层为线性输出, 即 $\hat{y} = s_1^{(3)}$ 。误差函数为: $E_{in} = \frac{1}{N} \sum_n (y_n - \hat{y}_n)^2$, 学习率为0.01。假设初始权系数矩阵定义如下:

$$\mathbf{w}_0^{(1)} = \begin{pmatrix} 1 & 1 \\ 1 & 1 \\ 1 & 1 \end{pmatrix}, \mathbf{w}_0^{(2)} = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix}, \mathbf{w}_0^{(3)} = \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \end{pmatrix}$$

其中 \mathbf{w} 的下标0代表迭代次数为0 (即初始状态), 上标数字分别代表第1、2、3层。要求将上述训练样本集的样本用反向传播法按顺序进行一轮训练, 写出每一次迭代时各层的权系数矩阵, 即: $t=1$ 时, 进入样本 \vec{x}_1 , 得到 $\mathbf{w}_1^{(1)}$ 、 $\mathbf{w}_1^{(2)}$ 和 $\mathbf{w}_1^{(3)}$; $t=2$ 时, 进入样本 \vec{x}_2 , 得到 $\mathbf{w}_2^{(1)}$ 、 $\mathbf{w}_2^{(2)}$ 和 $\mathbf{w}_2^{(3)}$; $t=3$ 时, 进入样本 \vec{x}_3 , 得到 $\mathbf{w}_3^{(1)}$ 、 $\mathbf{w}_3^{(2)}$ 和 $\mathbf{w}_3^{(3)}$; $t=4$ 时, 进入样本 \vec{x}_4 , 得到 $\mathbf{w}_4^{(1)}$ 、 $\mathbf{w}_4^{(2)}$ 和 $\mathbf{w}_4^{(3)}$

解:

(1) 算法步骤描述:

假设训练样本集有 N 个样本 $\{\vec{x}_1, \dots, \vec{x}_n, \dots, \vec{x}_N\}$, 每个样本有 d 维特征, 写成增广向量后是 $d+1$ 维, $\vec{x}_n = (1, x_{n1}, \dots, x_{nd})^T$, 将神经网络的输入层当第0层, 所以写为: $\vec{x}_n^{(0)} = (1, x_{n1}^{(0)}, \dots, x_{nd}^{(0)})^T$, 当 $d=2$ 时, $\vec{x}_n^{(0)} = (1, x_{n1}^{(0)}, x_{n2}^{(0)})^T$

假设第一层有两个神经元, 第二层有三个神经元, 第三层有一个神经元。

第一层、第二层和第三层的权系数矩阵分别为:

$$\mathbf{w}^{(1)} = \begin{pmatrix} w_{01}^{(1)} & w_{02}^{(1)} \\ w_{11}^{(1)} & w_{12}^{(1)} \\ w_{21}^{(1)} & w_{22}^{(1)} \end{pmatrix}, \quad \mathbf{w}^{(2)} = \begin{pmatrix} w_{01}^{(2)} & w_{02}^{(2)} & w_{03}^{(2)} \\ w_{11}^{(2)} & w_{12}^{(2)} & w_{13}^{(2)} \\ w_{21}^{(2)} & w_{22}^{(2)} & w_{23}^{(2)} \end{pmatrix}, \quad \mathbf{w}^{(3)} = \begin{pmatrix} w_{01}^{(3)} \\ w_{11}^{(3)} \\ w_{21}^{(3)} \\ w_{31}^{(3)} \end{pmatrix}$$

则第一层神经元的输入为：

$$\begin{pmatrix} s_1^{(1)} \\ s_2^{(1)} \end{pmatrix} = (\mathbf{w}^{(1)})^T \vec{x}_n^{(0)}$$

假设第一层神经元的激活函数为ReLU，即： $x^{(1)} = \max(0, s^{(1)})$ ，则：

$$\begin{pmatrix} x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} = \begin{pmatrix} \max(0, s_1^{(1)}) \\ \max(0, s_2^{(1)}) \end{pmatrix}$$

第二层神经元的输入为：

$$\begin{pmatrix} s_1^{(2)} \\ s_2^{(2)} \\ s_3^{(2)} \end{pmatrix} = (\mathbf{w}^{(2)})^T \begin{pmatrix} 1 \\ x_1^{(1)} \\ x_2^{(1)} \end{pmatrix}$$

假设第二层神经元的激活函数为ReLU，即： $x^{(2)} = \max(0, s^{(2)})$ ，则：

$$\begin{pmatrix} x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} = \begin{pmatrix} \max(0, s_1^{(2)}) \\ \max(0, s_2^{(2)}) \\ \max(0, s_3^{(2)}) \end{pmatrix}$$

则第三层的输入为：

$$s_1^{(3)} = (\mathbf{w}^{(3)})^T \begin{pmatrix} 1 \\ x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix}$$

因为第三层是线性操作，即输出 $\hat{y} = s_1^{(3)}$

对于输入样本 \vec{x}_n ，假设其标签为 y_n ，采用平方误差函数。即： $e_n = (y_n - \hat{y}_n)^2$

$$\delta_1^{(3)} = -2(y_n - s_1^{(3)})$$

运用反向传播法，于是： $\delta_j^{(2)} = \sum_k (\delta_k^{(3)})(w_{jk}^{(3)})(x_j^{(2)})'$

对于ReLU来说，其导数为： $(x_j^{(L)})' = \llbracket s_j^{(L-1)} \geq 0 \rrbracket$

所以: $\delta_j^{(2)} = \sum_k (\delta_k^{(3)})(w_{jk}^{(3)}) \llbracket s_j^{(2)} \geq 0 \rrbracket = \delta_1^{(3)} w_{j1}^{(3)} \llbracket s_j^{(2)} \geq 0 \rrbracket$

$$\text{即: } \vec{\delta}^{(2)} = \begin{pmatrix} \delta_1^{(2)} \\ \delta_2^{(2)} \\ \delta_3^{(2)} \end{pmatrix} = \begin{pmatrix} \delta_1^{(3)} w_{11}^{(3)} \llbracket s_1^{(2)} \geq 0 \rrbracket \\ \delta_1^{(3)} w_{21}^{(3)} \llbracket s_2^{(2)} \geq 0 \rrbracket \\ \delta_1^{(3)} w_{31}^{(3)} \llbracket s_3^{(2)} \geq 0 \rrbracket \end{pmatrix}$$

继续运用反向传播法, 于是: $\delta_j^{(1)} = \sum_k (\delta_k^{(2)})(w_{jk}^{(2)})(x_j^{(1)})'$, 所以:

$$\delta_j^{(1)} = \sum_k (\delta_k^{(2)})(w_{jk}^{(2)}) \llbracket s_j^{(1)} \geq 0 \rrbracket = (\delta_1^{(2)} w_{j1}^{(2)} + \delta_2^{(2)} w_{j2}^{(2)} + \delta_3^{(2)} w_{j3}^{(2)}) \llbracket s_j^{(1)} \geq 0 \rrbracket$$

由此可以得到:

$$\vec{\delta}^{(1)} = \begin{pmatrix} \delta_1^{(1)} \\ \delta_2^{(1)} \end{pmatrix} = \begin{pmatrix} \llbracket s_1^{(1)} \geq 0 \rrbracket & 0 \\ 0 & \llbracket s_2^{(1)} \geq 0 \rrbracket \end{pmatrix} \begin{pmatrix} w_{11}^{(2)} & w_{12}^{(2)} & w_{13}^{(2)} \\ w_{21}^{(2)} & w_{22}^{(2)} & w_{23}^{(2)} \end{pmatrix} \begin{pmatrix} \delta_1^{(2)} \\ \delta_2^{(2)} \\ \delta_3^{(2)} \end{pmatrix}$$

假定t表示迭代次数, η 为学习步长, 利用梯度下降法进行权系数更新:

$$\begin{aligned} \mathbf{w}_{t+1}^{(1)} &= \mathbf{w}_t^{(1)} - \eta \vec{x}_n^{(0)} (\vec{\delta}^{(1)})^T = \mathbf{w}_t^{(1)} - \eta \begin{pmatrix} 1 \\ x_{n1}^{(0)} \\ x_{n2}^{(0)} \end{pmatrix} (\delta_1^{(1)}, \delta_2^{(1)}) \\ &= \begin{pmatrix} w_{01}^{(1)} & w_{02}^{(1)} \\ w_{11}^{(1)} & w_{12}^{(1)} \\ w_{21}^{(1)} & w_{22}^{(1)} \end{pmatrix} - \eta \begin{pmatrix} \delta_1^{(1)} & \delta_2^{(1)} \\ x_{n1}^{(0)} \delta_1^{(1)} & x_{n1}^{(0)} \delta_2^{(1)} \\ x_{n2}^{(0)} \delta_1^{(1)} & x_{n2}^{(0)} \delta_2^{(1)} \end{pmatrix} \\ \mathbf{w}_{t+1}^{(2)} &= \mathbf{w}_t^{(2)} - \eta \vec{x}_n^{(1)} (\vec{\delta}^{(2)})^T = \mathbf{w}_t^{(2)} - \eta \begin{pmatrix} 1 \\ x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} (\delta_1^{(2)}, \delta_2^{(2)}, \delta_3^{(2)}) \\ &= \begin{pmatrix} w_{01}^{(2)} & w_{02}^{(2)} & w_{03}^{(2)} \\ w_{11}^{(2)} & w_{12}^{(2)} & w_{13}^{(2)} \\ w_{21}^{(2)} & w_{22}^{(2)} & w_{23}^{(2)} \end{pmatrix} - \eta \begin{pmatrix} \delta_1^{(2)} & \delta_2^{(2)} & \delta_3^{(2)} \\ x_1^{(1)} \delta_1^{(2)} & x_1^{(1)} \delta_2^{(2)} & x_1^{(1)} \delta_3^{(2)} \\ x_2^{(1)} \delta_1^{(2)} & x_2^{(1)} \delta_2^{(2)} & x_2^{(1)} \delta_3^{(2)} \end{pmatrix} \\ \mathbf{w}_{t+1}^{(3)} &= \mathbf{w}_t^{(3)} - \eta \vec{x}_n^{(2)} (\vec{\delta}^{(3)})^T = \mathbf{w}_t^{(3)} - \eta \begin{pmatrix} 1 \\ x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} \delta_1^{(3)} = \begin{pmatrix} w_{01}^{(3)} \\ w_{11}^{(3)} \\ w_{21}^{(3)} \\ w_{31}^{(3)} \end{pmatrix} - \eta \begin{pmatrix} \delta_1^{(3)} \\ x_1^{(2)} \delta_1^{(3)} \\ x_2^{(2)} \delta_1^{(3)} \\ x_3^{(2)} \delta_1^{(3)} \end{pmatrix} \end{aligned}$$

反复迭代至T次。

(2) 代入习题数据的解答流程:

t=0

$$\mathbf{w}_0^{(1)} = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}, \quad \mathbf{w}_0^{(2)} = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix}, \quad \mathbf{w}_0^{(3)} = \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \end{pmatrix}$$

t=1时，对于第一个样本 $\vec{x}_1 = (1,1)^T$ ，则第一层神经元的输入为：

$$\begin{pmatrix} s_1^{(1)} \\ s_2^{(1)} \end{pmatrix} = (\mathbf{w}^{(1)})^T \vec{x}_1^{(0)} = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 3 \\ 3 \end{pmatrix}$$

$$\text{则: } \begin{pmatrix} x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} = \begin{pmatrix} \max(0, s_1^{(1)}) \\ \max(0, s_2^{(1)}) \end{pmatrix} = \begin{pmatrix} 3 \\ 3 \end{pmatrix}$$

第二层神经元的输入为：

$$\begin{pmatrix} s_1^{(2)} \\ s_2^{(2)} \\ s_3^{(2)} \end{pmatrix} = (\mathbf{w}^{(2)})^T \begin{pmatrix} x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} 3 \\ 3 \end{pmatrix} = \begin{pmatrix} 7 \\ 7 \\ 7 \end{pmatrix}$$

$$\text{则: } \begin{pmatrix} x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} = \begin{pmatrix} 7 \\ 7 \\ 7 \end{pmatrix}$$

则第三层的输入为：

$$s_1^{(3)} = (\mathbf{w}^{(3)})^T \begin{pmatrix} x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} = \begin{pmatrix} 1 & 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} 7 \\ 7 \\ 7 \\ 7 \end{pmatrix} = 28$$

即输出 $\hat{y} = s_1^{(3)} = 28$

对于样本 \vec{x}_1 ，其标签为1，采用平方误差函数： $e_n = (y_n - \hat{y}_n)^2$ ，则：

$$\delta_1^{(3)} = -2(y_n - s_1^{(3)}) = -2(1 - 28) = 54$$

运用反向传播法，于是：

$$\delta_j^{(2)} = \sum_k (\delta_k^{(3)})(w_{jk}^{(3)}) \llbracket s_j^{(2)} \geq 0 \rrbracket = \delta_1^{(3)} w_{j1}^{(3)} \llbracket s_j^{(2)} \geq 0 \rrbracket$$

$$\text{即: } \vec{\delta}^{(2)} = \begin{pmatrix} \delta_1^{(2)} \\ \delta_2^{(2)} \\ \delta_3^{(2)} \end{pmatrix} = \begin{pmatrix} \delta_1^{(3)} w_{11}^{(3)} \llbracket s_1^{(2)} \geq 0 \rrbracket \\ \delta_1^{(3)} w_{21}^{(3)} \llbracket s_2^{(2)} \geq 0 \rrbracket \\ \delta_1^{(3)} w_{31}^{(3)} \llbracket s_3^{(2)} \geq 0 \rrbracket \end{pmatrix} = \begin{pmatrix} 42 * 1 * 1 \\ 42 * 1 * 1 \\ 42 * 1 * 1 \end{pmatrix} = \begin{pmatrix} 42 \\ 42 \\ 42 \end{pmatrix}$$

继续运用反向传播法, 于是: $\delta_j^{(1)} = \sum_k (\delta_k^{(2)})(w_{jk}^{(2)})(x_j^{(1)})'$, 所以:

$$\delta_j^{(1)} = \sum_k (\delta_k^{(2)})(w_{jk}^{(2)}) \llbracket s_j^{(1)} \geq 0 \rrbracket = (\delta_1^{(2)} w_{j1}^{(2)} + \delta_2^{(2)} w_{j2}^{(2)} + \delta_3^{(2)} w_{j3}^{(2)}) \llbracket s_j^{(1)} \geq 0 \rrbracket$$

由此可以得到:

$$\begin{aligned} \vec{\delta}^{(1)} = \begin{pmatrix} \delta_1^{(1)} \\ \delta_2^{(1)} \end{pmatrix} &= \begin{pmatrix} \llbracket s_1^{(1)} \geq 0 \rrbracket & 0 \\ 0 & \llbracket s_2^{(1)} \geq 0 \rrbracket \end{pmatrix} \begin{pmatrix} w_{11}^{(2)} & w_{12}^{(2)} & w_{13}^{(2)} \\ w_{21}^{(2)} & w_{22}^{(2)} & w_{23}^{(2)} \end{pmatrix} \begin{pmatrix} \delta_1^{(2)} \\ \delta_2^{(2)} \\ \delta_3^{(2)} \end{pmatrix} \\ &= \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} 42 \\ 42 \\ 42 \end{pmatrix} = \begin{pmatrix} 126 \\ 126 \end{pmatrix} \end{aligned}$$

令 $\eta = 0.01$, 利用梯度下降法进行权系数更新:

$$\begin{aligned} \mathbf{w}_1^{(1)} &= \mathbf{w}_0^{(1)} - \eta \vec{x}_n^{(0)} (\vec{\delta}^{(1)})^T = \mathbf{w}_t^{(1)} - \eta \begin{pmatrix} 1 \\ x_{n1}^{(0)} \\ x_{n2}^{(0)} \end{pmatrix} (\delta_1^{(1)}, \delta_2^{(1)}) \\ &= \begin{pmatrix} w_{01}^{(1)} & w_{02}^{(1)} \\ w_{11}^{(1)} & w_{12}^{(1)} \\ w_{21}^{(1)} & w_{22}^{(1)} \end{pmatrix} - \eta \begin{pmatrix} \delta_1^{(1)} & \delta_2^{(1)} \\ x_{n1}^{(0)} \delta_1^{(1)} & x_{n1}^{(0)} \delta_2^{(1)} \\ x_{n2}^{(0)} \delta_1^{(1)} & x_{n2}^{(0)} \delta_2^{(1)} \end{pmatrix} \\ &= \begin{pmatrix} 1 & 1 \\ 1 & 1 \\ 1 & 1 \end{pmatrix} - 0.01 \begin{pmatrix} 126 & 126 \\ 1 * 126 & 1 * 126 \\ 1 * 126 & 1 * 126 \end{pmatrix} = \begin{pmatrix} -0.26 & -0.26 \\ -0.26 & -0.26 \\ -0.26 & -0.26 \end{pmatrix} \end{aligned}$$

$$\begin{aligned} \mathbf{w}_1^{(2)} &= \mathbf{w}_0^{(2)} - \eta \vec{x}_n^{(1)} (\vec{\delta}^{(2)})^T = \mathbf{w}_0^{(2)} - \eta \begin{pmatrix} 1 \\ x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} (\delta_1^{(2)}, \delta_2^{(2)}, \delta_3^{(2)}) \\ &= \begin{pmatrix} w_{01}^{(2)} & w_{02}^{(2)} & w_{03}^{(2)} \\ w_{11}^{(2)} & w_{12}^{(2)} & w_{13}^{(2)} \\ w_{21}^{(2)} & w_{22}^{(2)} & w_{23}^{(2)} \end{pmatrix} - \eta \begin{pmatrix} \delta_1^{(2)} & \delta_2^{(2)} & \delta_3^{(2)} \\ x_1^{(1)} \delta_1^{(2)} & x_1^{(1)} \delta_2^{(2)} & x_1^{(1)} \delta_3^{(2)} \\ x_2^{(1)} \delta_1^{(2)} & x_2^{(1)} \delta_2^{(2)} & x_2^{(1)} \delta_3^{(2)} \end{pmatrix} \\ &= \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix} - 0.01 \begin{pmatrix} 42 & 42 & 42 \\ 3 * 42 & 3 * 42 & 3 * 42 \\ 3 * 42 & 3 * 42 & 3 * 42 \end{pmatrix} \\ &= \begin{pmatrix} 0.58 & 0.58 & 0.58 \\ -0.26 & -0.26 & -0.26 \\ -0.26 & -0.26 & -0.26 \end{pmatrix} \end{aligned}$$

$$\begin{aligned}\mathbf{w}_1^{(3)} &= \mathbf{w}_0^{(3)} - \eta \vec{x}_n^{(2)} \overrightarrow{\delta^{(3)}}^T = \mathbf{w}_0^{(3)} - \eta \begin{pmatrix} 1 \\ x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} \delta_1^{(3)} = \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \end{pmatrix} - 0.01 \begin{pmatrix} 42 \\ 7 * 42 \\ 7 * 42 \\ 7 * 42 \end{pmatrix} \\ &= \begin{pmatrix} 0.58 \\ -1.94 \\ -1.94 \\ -1.94 \end{pmatrix}\end{aligned}$$

t=2, 对于第二个样本 $\vec{x}_2 = (-1, -1)^T$, 则第一层神经元的输入为:

$$\begin{pmatrix} s_1^{(1)} \\ s_2^{(1)} \end{pmatrix} = (\mathbf{w}^{(1)})^T \vec{x}_n^{(0)} = \begin{pmatrix} -0.26 & -0.26 & -0.26 \\ -0.26 & -0.26 & -0.26 \end{pmatrix} \begin{pmatrix} 1 \\ -1 \\ -1 \end{pmatrix} = \begin{pmatrix} 0.26 \\ 0.26 \end{pmatrix}$$

$$\text{则: } \begin{pmatrix} x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} = \begin{pmatrix} \max(0, s_1^{(1)}) \\ \max(0, s_2^{(1)}) \end{pmatrix} = \begin{pmatrix} 0.26 \\ 0.26 \end{pmatrix}$$

第二层神经元的输入为:

$$\begin{pmatrix} s_1^{(2)} \\ s_2^{(2)} \\ s_3^{(2)} \end{pmatrix} = (\mathbf{w}^{(2)})^T \begin{pmatrix} 1 \\ x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} = \begin{pmatrix} 0.58 & -0.26 & -0.26 \\ 0.58 & -0.26 & -0.26 \\ 0.58 & -0.26 & -0.26 \end{pmatrix} \begin{pmatrix} 1 \\ 0.26 \\ 0.26 \end{pmatrix} = \begin{pmatrix} 0.44 \\ 0.44 \\ 0.44 \end{pmatrix}$$

$$\text{则: } \begin{pmatrix} x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} = \begin{pmatrix} 0.44 \\ 0.44 \\ 0.44 \end{pmatrix}$$

则第三层的输入为:

$$s_1^{(3)} = (\mathbf{w}^{(3)})^T \begin{pmatrix} 1 \\ x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} = \begin{pmatrix} 0.58 & -1.94 & -1.94 & -1.94 \end{pmatrix} \begin{pmatrix} 1 \\ 0.44 \\ 0.44 \\ 0.44 \end{pmatrix} = -1.98$$

即输出 $\hat{y} = s_1^{(3)} = -1.98$

对于样本 \vec{x}_2 , 其标签为1, 采用平方误差函数: $e_n = (y_n - \hat{y}_n)^2$, 则:

$$\delta_1^{(3)} = -2(y_n - s_1^{(3)}) = -2(1 - (-1.98)) = -5.96$$

运用反向传播法, 于是:

$$\delta_j^{(2)} = \sum_k (\delta_k^{(3)})(w_{jk}^{(3)}) \llbracket s_j^{(2)} \geq 0 \rrbracket = \delta_1^{(3)} w_{j1}^{(3)} \llbracket s_j^{(2)} \geq 0 \rrbracket$$

$$\text{即: } \vec{\delta}^{(2)} = \begin{pmatrix} \delta_1^{(2)} \\ \delta_2^{(2)} \\ \delta_3^{(2)} \end{pmatrix} = \begin{pmatrix} \delta_1^{(3)} w_{11}^{(3)} \llbracket s_1^{(2)} \geq 0 \rrbracket \\ \delta_1^{(3)} w_{21}^{(3)} \llbracket s_2^{(2)} \geq 0 \rrbracket \\ \delta_1^{(3)} w_{31}^{(3)} \llbracket s_3^{(2)} \geq 0 \rrbracket \end{pmatrix} = \begin{pmatrix} -5.96 * (-1.94) * 1 \\ -5.96 * (-1.94) * 1 \\ -5.96 * (-1.94) * 1 \end{pmatrix} = \begin{pmatrix} 11.56 \\ 11.56 \\ 11.56 \end{pmatrix}$$

继续运用反向传播法，于是： $\delta_j^{(1)} = \sum_k (\delta_k^{(2)})(w_{jk}^{(2)})(x_j^{(1)})'$ ，所以：

$$\delta_j^{(1)} = \sum_k (\delta_k^{(2)})(w_{jk}^{(2)}) \llbracket s_j^{(1)} \geq 0 \rrbracket = (\delta_1^{(2)} w_{j1}^{(2)} + \delta_2^{(2)} w_{j2}^{(2)} + \delta_3^{(2)} w_{j3}^{(2)}) \llbracket s_j^{(1)} \geq 0 \rrbracket$$

由此可以得到：

$$\vec{\delta}^{(1)} = \begin{pmatrix} \delta_1^{(1)} \\ \delta_2^{(1)} \end{pmatrix} = \begin{pmatrix} \llbracket s_1^{(1)} \geq 0 \rrbracket & 0 \\ 0 & \llbracket s_2^{(1)} \geq 0 \rrbracket \end{pmatrix} \begin{pmatrix} w_{11}^{(2)} & w_{12}^{(2)} & w_{13}^{(2)} \\ w_{21}^{(2)} & w_{22}^{(2)} & w_{23}^{(2)} \end{pmatrix} \begin{pmatrix} \delta_1^{(2)} \\ \delta_2^{(2)} \\ \delta_3^{(2)} \end{pmatrix}$$

$$= \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} -0.26 & -0.26 & -0.26 \\ -0.26 & -0.26 & -0.26 \end{pmatrix} \begin{pmatrix} 11.56 \\ 11.56 \\ 11.56 \end{pmatrix} = \begin{pmatrix} -9.02 \\ -9.02 \end{pmatrix}$$

令 $\eta = 0.01$ ，利用梯度下降法进行权系数更新：

$$\mathbf{w}_2^{(1)} = \mathbf{w}_1^{(1)} - \eta \vec{x}_n^{(0)} (\vec{\delta}^{(1)})^T = \mathbf{w}_1^{(1)} - \eta \begin{pmatrix} 1 \\ x_{n1}^{(0)} \\ x_{n2}^{(0)} \end{pmatrix} (\delta_1^{(1)}, \delta_2^{(1)})$$

$$= \begin{pmatrix} w_{01}^{(1)} & w_{02}^{(1)} \\ w_{11}^{(1)} & w_{12}^{(1)} \\ w_{21}^{(1)} & w_{22}^{(1)} \end{pmatrix} - \eta \begin{pmatrix} \delta_1^{(1)} & \delta_2^{(1)} \\ x_{n1}^{(0)} \delta_1^{(1)} & x_{n1}^{(0)} \delta_2^{(1)} \\ x_{n2}^{(0)} \delta_1^{(1)} & x_{n2}^{(0)} \delta_2^{(1)} \end{pmatrix}$$

$$= \begin{pmatrix} -0.26 & -0.26 \\ -0.26 & -0.26 \\ -0.26 & -0.26 \end{pmatrix} - 0.01 \begin{pmatrix} -9.02 & -9.02 \\ (-1) * (-9.02) & (-1) * (-9.02) \\ (-1) * (-9.02) & (-1) * (-9.02) \end{pmatrix}$$

$$= \begin{pmatrix} -0.17 & -0.17 \\ -0.35 & -0.35 \\ -0.35 & -0.35 \end{pmatrix}$$

$$\begin{aligned}
\mathbf{w}_2^{(2)} &= \mathbf{w}_1^{(2)} - \eta \vec{x}_n^{(1)} (\vec{\delta}^{(2)})^T = \mathbf{w}_1^{(2)} - \eta \begin{pmatrix} 1 \\ x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} (\delta_1^{(2)}, \delta_2^{(2)}, \delta_3^{(2)}) \\
&= \begin{pmatrix} w_{01}^{(2)} & w_{02}^{(2)} & w_{03}^{(2)} \\ w_{11}^{(2)} & w_{12}^{(2)} & w_{13}^{(2)} \\ w_{21}^{(2)} & w_{22}^{(2)} & w_{23}^{(2)} \end{pmatrix} - \eta \begin{pmatrix} \delta_1^{(2)} & \delta_2^{(2)} & \delta_3^{(2)} \\ x_1^{(1)} \delta_1^{(2)} & x_1^{(1)} \delta_2^{(2)} & x_1^{(1)} \delta_3^{(2)} \\ x_2^{(1)} \delta_1^{(2)} & x_2^{(1)} \delta_2^{(2)} & x_2^{(1)} \delta_3^{(2)} \end{pmatrix} \\
&= \begin{pmatrix} 0.58 & 0.58 & 0.58 \\ -0.26 & -0.26 & -0.26 \\ -0.26 & -0.26 & -0.26 \end{pmatrix} \\
&\quad - 0.01 \begin{pmatrix} 11.56 & 11.56 & 11.56 \\ 0.26 * 11.56 & 0.26 * 11.56 & 0.26 * 11.56 \\ 0.26 * 11.56 & 0.26 * 11.56 & 0.26 * 11.56 \end{pmatrix} \\
&= \begin{pmatrix} 0.46 & 0.46 & 0.46 \\ -0.29 & -0.29 & -0.29 \\ -0.29 & -0.29 & -0.29 \end{pmatrix}
\end{aligned}$$

$$\begin{aligned}
\mathbf{w}_2^{(3)} &= \mathbf{w}_1^{(3)} - \eta \vec{x}_n^{(2)} (\vec{\delta}^{(3)})^T = \mathbf{w}_1^{(3)} - \eta \begin{pmatrix} 1 \\ x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} \delta_1^{(3)} \\
&= \begin{pmatrix} 0.58 \\ -1.94 \\ -1.94 \\ -1.94 \end{pmatrix} - 0.01 \begin{pmatrix} -5.96 \\ 0.44 * (-5.96) \\ 0.44 * (-5.96) \\ 0.44 * (-5.96) \end{pmatrix} = \begin{pmatrix} 0.64 \\ -1.91 \\ -1.91 \\ -1.91 \end{pmatrix}
\end{aligned}$$

t=3, 对于第三个样本 $\vec{x}_3 = (-1, 1)^T$, 则第一层神经元的输入为:

$$\begin{pmatrix} s_1^{(1)} \\ s_2^{(1)} \end{pmatrix} = (\mathbf{w}^{(1)})^T \vec{x}_n^{(0)} = \begin{pmatrix} -0.17 & -0.35 & -0.35 \\ -0.17 & -0.35 & -0.35 \end{pmatrix} \begin{pmatrix} 1 \\ -1 \\ 1 \end{pmatrix} = \begin{pmatrix} -0.17 \\ -0.17 \end{pmatrix}$$

$$\text{则: } \begin{pmatrix} x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} = \begin{pmatrix} \max(0, s_1^{(1)}) \\ \max(0, s_2^{(1)}) \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

第二层神经元的输入为:

$$\begin{pmatrix} s_1^{(2)} \\ s_2^{(2)} \\ s_3^{(2)} \end{pmatrix} = (\mathbf{w}^{(2)})^T \begin{pmatrix} 1 \\ x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} = \begin{pmatrix} 0.46 & -0.29 & -0.29 \\ 0.46 & -0.29 & -0.29 \\ 0.46 & -0.29 & -0.29 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 0.46 \\ 0.46 \\ 0.46 \end{pmatrix}$$

$$\text{则: } \begin{pmatrix} x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} = \begin{pmatrix} 0.46 \\ 0.46 \\ 0.46 \end{pmatrix}$$

则第三层的输入为：

$$s_1^{(3)} = (\mathbf{w}^{(3)})^T \begin{pmatrix} 1 \\ x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} = (0.64 \quad -1.91 \quad -1.91 \quad -1.91) \begin{pmatrix} 1 \\ 0.46 \\ 0.46 \\ 0.46 \end{pmatrix} = -2.00$$

即输出 $\hat{y} = s_1^{(3)} = -2.00$

对于样本 \vec{x}_3 ，其标签为 -1 ，采用平方误差函数： $e_n = (y_n - \hat{y}_n)^2$ ，则：

$$\delta_1^{(3)} = -2(y_n - s_1^{(3)}) = -2(-1 - (-2.00)) = -2.00$$

运用反向传播法，于是：

$$\delta_j^{(2)} = \sum_k (\delta_k^{(3)})(w_{jk}^{(3)}) \llbracket s_j^{(2)} \geq 0 \rrbracket = \delta_1^{(3)} w_{j1}^{(3)} \llbracket s_j^{(2)} \geq 0 \rrbracket$$

$$\text{即：} \vec{\delta}^{(2)} = \begin{pmatrix} \delta_1^{(2)} \\ \delta_2^{(2)} \\ \delta_3^{(2)} \end{pmatrix} = \begin{pmatrix} \delta_1^{(3)} w_{11}^{(3)} \llbracket s_1^{(2)} \geq 0 \rrbracket \\ \delta_1^{(3)} w_{21}^{(3)} \llbracket s_2^{(2)} \geq 0 \rrbracket \\ \delta_1^{(3)} w_{31}^{(3)} \llbracket s_3^{(2)} \geq 0 \rrbracket \end{pmatrix} = \begin{pmatrix} (-2.00) * (-1.91) * 1 \\ (-2.00) * (-1.91) * 1 \\ (-2.00) * (-1.91) * 1 \end{pmatrix} = \begin{pmatrix} 3.82 \\ 3.82 \\ 3.82 \end{pmatrix}$$

继续运用反向传播法，于是： $\delta_j^{(1)} = \sum_k (\delta_k^{(2)})(w_{jk}^{(2)})(x_j^{(1)})'$ ，所以：

$$\delta_j^{(1)} = \sum_k (\delta_k^{(2)})(w_{jk}^{(2)}) \llbracket s_j^{(1)} \geq 0 \rrbracket = (\delta_1^{(2)} w_{j1}^{(2)} + \delta_2^{(2)} w_{j2}^{(2)} + \delta_3^{(2)} w_{j3}^{(2)}) \llbracket s_j^{(1)} \geq 0 \rrbracket$$

由此可以得到：

$$\vec{\delta}^{(1)} = \begin{pmatrix} \delta_1^{(1)} \\ \delta_2^{(1)} \end{pmatrix} = \begin{pmatrix} \llbracket s_1^{(1)} \geq 0 \rrbracket & 0 \\ 0 & \llbracket s_2^{(1)} \geq 0 \rrbracket \end{pmatrix} \begin{pmatrix} w_{11}^{(2)} & w_{12}^{(2)} & w_{13}^{(2)} \\ w_{21}^{(2)} & w_{22}^{(2)} & w_{23}^{(2)} \end{pmatrix} \begin{pmatrix} \delta_1^{(2)} \\ \delta_2^{(2)} \\ \delta_3^{(2)} \end{pmatrix}$$

$$= \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} -0.29 & -0.29 & -0.29 \\ -0.29 & -0.29 & -0.29 \end{pmatrix} \begin{pmatrix} 3.82 \\ 3.82 \\ 3.82 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

令 $\eta = 0.01$ ，利用梯度下降法进行权系数更新：

$$\begin{aligned}
\mathbf{w}_3^{(1)} &= \mathbf{w}_2^{(1)} - \eta \vec{x}_n^{(0)} (\vec{\delta}^{(1)})^T = \mathbf{w}_2^{(1)} - \eta \begin{pmatrix} 1 \\ x_{n1}^{(0)} \\ x_{n2}^{(0)} \end{pmatrix} (\delta_1^{(1)}, \delta_2^{(1)}) \\
&= \begin{pmatrix} w_{01}^{(1)} & w_{02}^{(1)} \\ w_{11}^{(1)} & w_{12}^{(1)} \\ w_{21}^{(1)} & w_{22}^{(1)} \end{pmatrix} - \eta \begin{pmatrix} \delta_1^{(1)} & \delta_2^{(1)} \\ x_{n1}^{(0)} \delta_1^{(1)} & x_{n1}^{(0)} \delta_2^{(1)} \\ x_{n2}^{(0)} \delta_1^{(1)} & x_{n2}^{(0)} \delta_2^{(1)} \end{pmatrix} \\
&= \begin{pmatrix} -0.17 & -0.17 \\ -0.35 & -0.35 \\ -0.35 & -0.35 \end{pmatrix} - 0.01 \begin{pmatrix} 0 & 0 \\ (-1) * 0 & (-1) * 0 \\ (+1) * 0 & (+1) * 0 \end{pmatrix} \\
&= \begin{pmatrix} -0.17 & -0.17 \\ -0.35 & -0.35 \\ -0.35 & -0.35 \end{pmatrix}
\end{aligned}$$

$$\begin{aligned}
\mathbf{w}_3^{(2)} &= \mathbf{w}_2^{(2)} - \eta \vec{x}_n^{(1)} (\vec{\delta}^{(2)})^T = \mathbf{w}_2^{(2)} - \eta \begin{pmatrix} 1 \\ x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} (\delta_1^{(2)}, \delta_2^{(2)}, \delta_3^{(2)}) \\
&= \begin{pmatrix} w_{01}^{(2)} & w_{02}^{(2)} & w_{03}^{(2)} \\ w_{11}^{(2)} & w_{12}^{(2)} & w_{13}^{(2)} \\ w_{21}^{(2)} & w_{22}^{(2)} & w_{23}^{(2)} \end{pmatrix} - \eta \begin{pmatrix} \delta_1^{(2)} & \delta_2^{(2)} & \delta_3^{(2)} \\ x_1^{(1)} \delta_1^{(2)} & x_1^{(1)} \delta_2^{(2)} & x_1^{(1)} \delta_3^{(2)} \\ x_2^{(1)} \delta_1^{(2)} & x_2^{(1)} \delta_2^{(2)} & x_2^{(1)} \delta_3^{(2)} \end{pmatrix} \\
&= \begin{pmatrix} 0.46 & 0.46 & 0.46 \\ -0.29 & -0.29 & -0.29 \\ -0.29 & -0.29 & -0.29 \end{pmatrix} - 0.01 \begin{pmatrix} 3.82 & 3.82 & 3.82 \\ 0 * 3.82 & 0 * 3.82 & 0 * 3.82 \\ 0 * 3.82 & 0 * 3.82 & 0 * 3.82 \end{pmatrix} \\
&= \begin{pmatrix} 0.42 & 0.42 & 0.42 \\ -0.29 & -0.29 & -0.29 \\ -0.29 & -0.29 & -0.29 \end{pmatrix}
\end{aligned}$$

$$\begin{aligned}
\mathbf{w}_3^{(3)} &= \mathbf{w}_2^{(3)} - \eta \vec{x}_n^{(2)} (\vec{\delta}^{(3)})^T = \mathbf{w}_2^{(3)} - \eta \begin{pmatrix} 1 \\ x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} \delta_1^{(3)} \\
&= \begin{pmatrix} 0.64 \\ -1.91 \\ -1.91 \\ -1.91 \end{pmatrix} - 0.01 \begin{pmatrix} -2.00 \\ 0.46 * (-2.00) \\ 0.46 * (-2.00) \\ 0.46 * (-2.00) \end{pmatrix} = \begin{pmatrix} 0.66 \\ -1.90 \\ -1.90 \\ -1.90 \end{pmatrix}
\end{aligned}$$

t=4, 对于第四个样本 $\vec{x}_2 = (1, -1)^T$, 则第一层神经元的输入为:

$$\begin{pmatrix} s_1^{(1)} \\ s_2^{(1)} \end{pmatrix} = (\mathbf{w}^{(1)})^T \vec{x}_n^{(0)} = \begin{pmatrix} -0.17 & -0.35 & -0.35 \\ -0.17 & -0.35 & -0.35 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ -1 \end{pmatrix} = \begin{pmatrix} -0.17 \\ -0.17 \end{pmatrix}$$

$$\text{则: } \begin{pmatrix} x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} = \begin{pmatrix} \max(0, s_1^{(1)}) \\ \max(0, s_2^{(1)}) \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

第二层神经元的输入为:

$$\begin{pmatrix} s_1^{(2)} \\ s_2^{(2)} \\ s_3^{(2)} \end{pmatrix} = (\mathbf{w}^{(2)})^T \begin{pmatrix} 1 \\ x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} = \begin{pmatrix} 0.42 & -0.29 & -0.29 \\ 0.42 & -0.29 & -0.29 \\ 0.42 & -0.29 & -0.29 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 0.42 \\ 0.42 \\ 0.42 \end{pmatrix}$$

$$\text{则: } \begin{pmatrix} x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} = \begin{pmatrix} 0.42 \\ 0.42 \\ 0.42 \end{pmatrix}$$

则第三层的输入为:

$$s_1^{(3)} = (\mathbf{w}^{(3)})^T \begin{pmatrix} 1 \\ x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} = \begin{pmatrix} 0.66 & -1.90 & -1.90 & -1.90 \end{pmatrix} \begin{pmatrix} 1 \\ 0.42 \\ 0.42 \\ 0.42 \end{pmatrix} = -1.73$$

$$\text{即输出 } \hat{y} = s_1^{(3)} = -1.73$$

对于样本 \vec{x}_4 , 其标签为 -1 , 采用平方误差函数: $e_n = (y_n - \hat{y}_n)^2$, 则:

$$\delta_1^{(3)} = -2(y_n - s_1^{(3)}) = -2(-1 - (-1.73)) = -1.46$$

运用反向传播法, 于是:

$$\delta_j^{(2)} = \sum_k (\delta_k^{(3)})(w_{jk}^{(3)}) \llbracket s_j^{(2)} \geq 0 \rrbracket = \delta_1^{(3)} w_{j1}^{(3)} \llbracket s_j^{(2)} \geq 0 \rrbracket$$

$$\text{即: } \vec{\delta}^{(2)} = \begin{pmatrix} \delta_1^{(2)} \\ \delta_2^{(2)} \\ \delta_3^{(2)} \end{pmatrix} = \begin{pmatrix} \delta_1^{(3)} w_{11}^{(3)} \llbracket s_1^{(2)} \geq 0 \rrbracket \\ \delta_1^{(3)} w_{21}^{(3)} \llbracket s_2^{(2)} \geq 0 \rrbracket \\ \delta_1^{(3)} w_{31}^{(3)} \llbracket s_3^{(2)} \geq 0 \rrbracket \end{pmatrix} = \begin{pmatrix} (-1.46) * (-1.90) * 1 \\ (-1.46) * (-1.90) * 1 \\ (-1.46) * (-1.90) * 1 \end{pmatrix} = \begin{pmatrix} 2.77 \\ 2.77 \\ 2.77 \end{pmatrix}$$

继续运用反向传播法, 于是: $\delta_j^{(1)} = \sum_k (\delta_k^{(2)})(w_{jk}^{(2)})(x_j^{(1)})'$, 所以:

$$\delta_j^{(1)} = \sum_k (\delta_k^{(2)})(w_{jk}^{(2)}) \llbracket s_j^{(1)} \geq 0 \rrbracket = (\delta_1^{(2)} w_{j1}^{(2)} + \delta_2^{(2)} w_{j2}^{(2)} + \delta_3^{(2)} w_{j3}^{(2)}) \llbracket s_j^{(1)} \geq 0 \rrbracket$$

由此可以得到:

$$\begin{aligned}\vec{\delta}^{(1)} = \begin{pmatrix} \delta_1^{(1)} \\ \delta_2^{(1)} \end{pmatrix} &= \begin{pmatrix} \llbracket s_1^{(1)} \geq 0 \rrbracket & 0 \\ 0 & \llbracket s_2^{(1)} \geq 0 \rrbracket \end{pmatrix} \begin{pmatrix} w_{11}^{(2)} & w_{12}^{(2)} & w_{13}^{(2)} \\ w_{21}^{(2)} & w_{22}^{(2)} & w_{23}^{(2)} \end{pmatrix} \begin{pmatrix} \delta_1^{(2)} \\ \delta_2^{(2)} \\ \delta_3^{(2)} \end{pmatrix} \\ &= \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} -0.29 & -0.29 & -0.29 \\ -0.29 & -0.29 & -0.29 \end{pmatrix} \begin{pmatrix} 2.77 \\ 2.77 \\ 2.77 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}\end{aligned}$$

令 $\eta = 0.01$ ，利用梯度下降法进行权系数更新：

$$\begin{aligned}\mathbf{w}_4^{(1)} &= \mathbf{w}_3^{(1)} - \eta \vec{x}_n^{(0)} (\vec{\delta}^{(1)})^T = \mathbf{w}_3^{(1)} - \eta \begin{pmatrix} 1 \\ x_{n1}^{(0)} \\ x_{n2}^{(0)} \end{pmatrix} (\delta_1^{(1)}, \delta_2^{(1)}) \\ &= \begin{pmatrix} w_{01}^{(1)} & w_{02}^{(1)} \\ w_{11}^{(1)} & w_{12}^{(1)} \\ w_{21}^{(1)} & w_{22}^{(1)} \end{pmatrix} - \eta \begin{pmatrix} \delta_1^{(1)} & \delta_2^{(1)} \\ x_{n1}^{(0)} \delta_1^{(1)} & x_{n1}^{(0)} \delta_2^{(1)} \\ x_{n2}^{(0)} \delta_1^{(1)} & x_{n2}^{(0)} \delta_2^{(1)} \end{pmatrix} \\ &= \begin{pmatrix} -0.17 & -0.17 \\ -0.35 & -0.35 \\ -0.35 & -0.35 \end{pmatrix} - 0.01 \begin{pmatrix} 0 & 0 \\ (+1) * 0 & (+1) * 0 \\ (-1) * 0 & (-1) * 0 \end{pmatrix} \\ &= \begin{pmatrix} -0.17 & -0.17 \\ -0.35 & -0.35 \\ -0.35 & -0.35 \end{pmatrix} \\ \mathbf{w}_4^{(2)} &= \mathbf{w}_3^{(2)} - \eta \vec{x}_n^{(1)} (\vec{\delta}^{(2)})^T = \mathbf{w}_3^{(2)} - \eta \begin{pmatrix} 1 \\ x_1^{(1)} \\ x_2^{(1)} \end{pmatrix} (\delta_1^{(2)}, \delta_2^{(2)}, \delta_3^{(2)}) \\ &= \begin{pmatrix} w_{01}^{(2)} & w_{02}^{(2)} & w_{03}^{(2)} \\ w_{11}^{(2)} & w_{12}^{(2)} & w_{13}^{(2)} \\ w_{21}^{(2)} & w_{22}^{(2)} & w_{23}^{(2)} \end{pmatrix} - \eta \begin{pmatrix} \delta_1^{(2)} & \delta_2^{(2)} & \delta_3^{(2)} \\ x_1^{(1)} \delta_1^{(2)} & x_1^{(1)} \delta_2^{(2)} & x_1^{(1)} \delta_3^{(2)} \\ x_2^{(1)} \delta_1^{(2)} & x_2^{(1)} \delta_2^{(2)} & x_2^{(1)} \delta_3^{(2)} \end{pmatrix} \\ &= \begin{pmatrix} 0.42 & 0.42 & 0.42 \\ -0.29 & -0.29 & -0.29 \\ -0.29 & -0.29 & -0.29 \end{pmatrix} - 0.01 \begin{pmatrix} 2.77 & 2.77 & 2.77 \\ 0 * 2.77 & 0 * 2.77 & 0 * 2.77 \\ 0 * 2.77 & 0 * 2.77 & 0 * 2.77 \end{pmatrix} \\ &= \begin{pmatrix} 0.39 & 0.39 & 0.39 \\ -0.29 & -0.29 & -0.29 \\ -0.29 & -0.29 & -0.29 \end{pmatrix}\end{aligned}$$

$$\begin{aligned}
\mathbf{w}_4^{(3)} &= \mathbf{w}_3^{(3)} - \eta \vec{x}_n^{(2)} (\vec{\delta}^{(3)})^T = \mathbf{w}_3^{(3)} - \eta \begin{pmatrix} 1 \\ x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{pmatrix} \delta_1^{(3)} \\
&= \begin{pmatrix} 0.66 \\ -1.90 \\ -1.90 \\ -1.90 \end{pmatrix} - 0.01 \begin{pmatrix} -1.46 \\ 0.42 * (-1.46) \\ 0.42 * (-1.46) \\ 0.42 * (-1.46) \end{pmatrix} = \begin{pmatrix} 0.67 \\ -1.89 \\ -1.89 \\ -1.89 \end{pmatrix}
\end{aligned}$$