

## 线性回归作业解答

1, 假设训练样本集为  $D = \{(\mathbf{x}_1, y_1) = ((2, 2)^T, 1), (\mathbf{x}_2, y_2) = ((4, 1)^T, 1), (\mathbf{x}_3, y_3) = ((1, 0)^T, -1)\}$ , 使用线性回归算法 (Linear Regression Algorithm), 通过广义逆来求解, 并设计这两类的分类函数, 判断测试样本  $\mathbf{x} = (0, 1)^T$  属于哪个类别, 与 L9 习题 1 设计的分类器相比较, 讨论结果。

解: 令  $D = \{(\mathbf{x}_i, y_i) = ((1, x_{1i}, x_{2i}), y_i)\}, i = 1, 2, 3$ , 故可写出:

$$X = \begin{pmatrix} 1 & 2 & 2 \\ 1 & 4 & 1 \\ 1 & 1 & 0 \end{pmatrix}, X^T = \begin{pmatrix} 1 & 1 & 1 \\ 2 & 4 & 1 \\ 2 & 1 & 0 \end{pmatrix}, Y = \begin{pmatrix} 1 \\ 1 \\ -1 \end{pmatrix}$$

$$X^T X = \begin{pmatrix} 1 & 1 & 1 \\ 2 & 4 & 1 \\ 2 & 1 & 0 \end{pmatrix} \begin{pmatrix} 1 & 2 & 2 \\ 1 & 4 & 1 \\ 1 & 1 & 0 \end{pmatrix} = \begin{pmatrix} 3 & 7 & 3 \\ 7 & 21 & 8 \\ 3 & 8 & 5 \end{pmatrix}$$

$$(X^T X)^{-1} = \begin{pmatrix} 1.64 & -0.44 & -0.28 \\ -0.44 & 0.24 & -0.12 \\ -0.28 & -0.12 & 0.56 \end{pmatrix}$$

计算广义逆:

$$X^\dagger = (X^T X)^{-1} X^T = \begin{pmatrix} 0.20 & -0.40 & 1.20 \\ -0.20 & 0.40 & -0.20 \\ 0.6 & -0.20 & -0.40 \end{pmatrix}$$

因此:

$$\mathbf{w}^* = X^\dagger Y = \begin{pmatrix} 0.20 & -0.40 & 1.20 \\ -0.20 & 0.40 & -0.20 \\ 0.6 & -0.20 & -0.40 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ -1 \end{pmatrix} = \begin{pmatrix} -1.4 \\ 0.4 \\ 0.8 \end{pmatrix}$$

对于样本  $\mathbf{x} = (0, 1)^T$ , 所属类别为:

$$\text{sign}(\mathbf{w}^{*T} \mathbf{x}) = \text{sign}((-1.4, 0.4, 0.8)(1, 0, 1)^T) = -1, \therefore \mathbf{x} \in -1 \text{ 类}$$

讨论: 同样的训练样本得到不同的分类面, 导致测试结果不同。

2, 根据向量或矩阵的计算性质, 证明:

$$\|\mathbf{X}\mathbf{w} - \mathbf{Y}\|^2 = \mathbf{w}^T \mathbf{X}^T \mathbf{X} \mathbf{w} - 2\mathbf{w}^T \mathbf{X}^T \mathbf{Y} + \mathbf{Y}^T \mathbf{Y}$$

解:

$$\begin{aligned} \|\mathbf{X}\mathbf{w} - \mathbf{Y}\|^2 &= (\mathbf{X}\mathbf{w} - \mathbf{Y})^T (\mathbf{X}\mathbf{w} - \mathbf{Y}) \\ &= ((\mathbf{X}\mathbf{w})^T - \mathbf{Y}^T) (\mathbf{X}\mathbf{w} - \mathbf{Y}) \\ &= (\mathbf{w}^T \mathbf{X}^T - \mathbf{Y}^T) (\mathbf{X}\mathbf{w} - \mathbf{Y}) \\ &= \mathbf{w}^T \mathbf{X}^T \mathbf{X} \mathbf{w} - \mathbf{w}^T \mathbf{X}^T \mathbf{Y} - \mathbf{Y}^T \mathbf{X} \mathbf{w} + \mathbf{Y}^T \mathbf{Y} \\ &= \mathbf{w}^T \mathbf{X}^T \mathbf{X} \mathbf{w} - \mathbf{w}^T \mathbf{X}^T \mathbf{Y} - (\mathbf{X}\mathbf{w})^T \mathbf{Y} + \mathbf{Y}^T \mathbf{Y} \\ &= \mathbf{w}^T \mathbf{X}^T \mathbf{X} \mathbf{w} - \mathbf{w}^T \mathbf{X}^T \mathbf{Y} - \mathbf{w}^T \mathbf{X}^T \mathbf{Y} + \mathbf{Y}^T \mathbf{Y} \\ &= \mathbf{w}^T \mathbf{X}^T \mathbf{X} \mathbf{w} - 2\mathbf{w}^T \mathbf{X}^T \mathbf{Y} + \mathbf{Y}^T \mathbf{Y} \end{aligned}$$

3, 假设在线性回归问题中,  $p(y|\mathbf{x}, \boldsymbol{\theta}) = \mathcal{N}(y|\mathbf{w}^T \mathbf{x}, \sigma^2)$ , 其中方差 $\sigma^2$ 是一个确定值, 请写出参数 $\mathbf{w}$ 的似然函数 $\mathcal{L}(\mathbf{w})$ , 并证明在这个情况下线性回归的最大化似然等价于最小二乘法, 并通过推导似然函数 $\mathcal{L}(\mathbf{w})$ 的梯度, 求出参数 $\mathbf{w}$ 的最大似然估计 $\mathbf{w}^*$

解:

$$\text{因为: } p(y|\mathbf{x}, \boldsymbol{\theta}) = \mathcal{N}(y|\mathbf{w}^T \mathbf{x}, \sigma^2)$$

说明:

给定输入 $\mathbf{x}$ 和模型中的各项参数,  $y$  是正态分布, 其均值是对 $\mathbf{x}$ 的线性预测, 假设训练样本数为  $N$ , 则:

$$\begin{aligned}
\mathcal{L}(\boldsymbol{\theta}) &= \mathcal{L}(\mathbf{w}) = \mathcal{L}(D|\mathbf{w}) = \sum_{n=1}^N \log p(y_n|\mathbf{x}_n, \mathbf{w}) \\
&= \sum_{n=1}^N \log \left( \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2} (y_n - \mathbf{w}^T \mathbf{x}_n)^2\right) \right) \\
&= -\frac{1}{2\sigma^2} \sum_{n=1}^N (y_n - \mathbf{w}^T \mathbf{x}_n)^2 - \frac{N}{2} \log(2\pi\sigma^2) \\
&= -\frac{1}{2\sigma^2} \|\mathbf{X}\mathbf{w} - \mathbf{Y}\|^2 - \frac{N}{2} \log(2\pi\sigma^2)
\end{aligned}$$

上式的第二项为常数，所以最大化似然就等价于线性回归问题中的最小二乘法：

$$\begin{aligned}
\min_{\mathbf{w}} \ell_{in}(\mathbf{w}) &= \frac{1}{2\sigma^2} \|\mathbf{X}\mathbf{w} - \mathbf{Y}\|^2 \\
\frac{\partial \mathcal{L}(\mathbf{w})}{\partial \mathbf{w}} &= \frac{1}{2\sigma^2} 2\mathbf{X}^T (\mathbf{X}\mathbf{w} - \mathbf{Y}) = \mathbf{0} \\
\mathbf{w}^* &= (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}
\end{aligned}$$

可见，利用最大似然求得的最佳 $\mathbf{w}^*$ 与最小二乘法得到的结果一致。

4，总结梯度下降法、随机梯度下降法、Adagrad、RMSProp、动量法（Momentum）和 Adam 等方法权系数更新表达式。

解：对于任意的损失函数 $\ell$ ，假设任一单个样本  $n$  的梯度 $\nabla \ell_n(\mathbf{w})$ ， $t$  代表迭代次数

（1）梯度下降法：

$$\nabla \ell_{in}(\mathbf{w}) = \frac{1}{N} \sum_{n=1}^N \nabla \ell_n(\mathbf{w})$$

$$\mathbf{w}_{t+1} \leftarrow \mathbf{w}_t - \eta \nabla \ell_{in}(\mathbf{w}_t)$$

(2) 随机梯度下降法:

$$\nabla \ell_{in}(\mathbf{w}) = \frac{1}{B} \sum_{n=1}^B \nabla \ell_n(\mathbf{w}), \quad B \text{ 代表批量大小, 最小可以为 } 1$$

$$\mathbf{w}_{t+1} \leftarrow \mathbf{w}_t - \eta \nabla \ell_{in}(\mathbf{w}_t)$$

(3) Adagrad:

$$\nabla \ell_{in}(\mathbf{w}) = \frac{1}{B} \sum_{n=1}^B \nabla \ell_n(\mathbf{w})$$

$$\sigma_t = \sqrt{\frac{1}{t+1} \sum_{t=0}^t (\nabla \ell_{in}(\mathbf{w}))^2 + \varepsilon}, \quad \varepsilon \text{ 代表极小量, 防止 } \sigma_t \text{ 为 } 0$$

$$\mathbf{w}_{t+1} \leftarrow \mathbf{w}_t - \frac{\eta}{\sqrt{t+1}\sigma_t} \nabla \ell_{in}(\mathbf{w}_t)$$

(4) RMSProp:

$$\nabla \ell_{in}(\mathbf{w}) = \frac{1}{B} \sum_{n=1}^B \nabla \ell_n(\mathbf{w})$$

$$\sigma_{t-1} = \sqrt{\frac{1}{t} \sum_{t=0}^{t-1} (\nabla \ell_{in}(\mathbf{w}))^2}$$

$$\sigma_t = \sqrt{\alpha(\sigma_{t-1})^2 + (1 - \alpha)(\nabla \ell_{in}(\mathbf{w}))^2 + \varepsilon}$$

$$\mathbf{w}_{t+1} \leftarrow \mathbf{w}_t - \frac{\eta}{\sigma_t} \nabla \ell_{in}(\mathbf{w}_t)$$

(5) 动量法 (Momentum):

$$\nabla \ell_{in}(\mathbf{w}) = \frac{1}{B} \sum_{n=1}^B \nabla \ell_n(\mathbf{w})$$

$$\mathbf{m}_{t+1} = \lambda \mathbf{m}_t - \eta \nabla \ell_{in}(\mathbf{w}_t), \quad (\mathbf{m}_0 = 0)$$

$$\mathbf{w}_{t+1} \leftarrow \mathbf{w}_t + \mathbf{m}_{t+1}$$

(6) Adam

$$\mathbf{m}_{t+1} = \beta_1 \mathbf{m}_t - (1 - \beta_1) \nabla \ell_{in}(\mathbf{w}_t), \quad (\mathbf{m}_0 = 0)$$

$$\mathbf{v}_{t+1} = \beta_2 \mathbf{v}_t - (1 - \beta_2) (\nabla \ell_{in}(\mathbf{w}))^2, \quad (\mathbf{v}_0 = 0)$$

---

$$\hat{\mathbf{m}}_{t+1} = \mathbf{m}_{t+1}/(1 - \beta_1^{t+1})$$

$$\hat{\mathbf{v}}_{t+1} = \mathbf{v}_{t+1}/(1 - \beta_2^{t+1})$$

$$\mathbf{w}_{t+1} \leftarrow \mathbf{w}_t - \eta \hat{\mathbf{m}}_{t+1}/(\sqrt{\hat{\mathbf{v}}_{t+1}} + \varepsilon)$$

版权归SMART-AIA-HUST所有，严禁复制